

ĐẠI HỌC HUẾ
TRƯỜNG ĐẠI HỌC KHOA HỌC
KHOA CÔNG NGHỆ THÔNG TIN

KHÓA LUẬN TỐT NGHIỆP

NGHIÊN CỨU KỸ THUẬT ĐIỀU PHỐI GRADIENT VÀ TÍNH LỌC DỮ LIỆU NHẪM TỐI ƯU HÓA MÔ HÌNH NHẬN DẠNG KHUÔN MẶT 6-BIT

Sinh viên thực hiện: Hoàng Kim Thiên
Ngành: Khoa học máy tính
Giảng viên hướng dẫn: TS. Lê Quang Chiến

Thừa Thiên Huế, 2026

Lời cảm ơn

Trong quá trình thực hiện và hoàn thiện khóa luận tốt nghiệp này, tôi đã nhận được nhiều sự quan tâm, hướng dẫn và động viên quý báu từ thầy cô, gia đình, bạn bè và những người đã đồng hành cùng tôi. Tôi xin được bày tỏ lòng biết ơn chân thành đến tất cả mọi người đã hỗ trợ tôi trong suốt thời gian qua.

Trước hết, tôi xin gửi lời cảm ơn sâu sắc đến thầy TS. Lê Quang Chiến, người đã tận tình hướng dẫn, định hướng và góp ý cho tôi trong quá trình thực hiện đề tài. Những chỉ dẫn chuyên môn, kinh nghiệm nghiên cứu và sự hỗ trợ của thầy là nền tảng quan trọng giúp tôi từng bước hoàn thiện nội dung khóa luận. Tôi cũng xin chân thành cảm ơn các thầy cô và các chuyên gia tư vấn tại Khoa Công nghệ thông tin, Trường Đại học Khoa học, Đại học Huế đã truyền đạt kiến thức, tạo điều kiện học tập và hỗ trợ tôi trong quá trình nghiên cứu.

Tôi xin gửi lời cảm ơn đến gia đình, những người luôn ở bên cạnh, động viên và tạo điều kiện tốt nhất để tôi yên tâm học tập, nghiên cứu. Sự tin tưởng, yêu thương và ủng hộ của gia đình là nguồn động lực lớn giúp tôi vượt qua những khó khăn trong quá trình thực hiện khóa luận.

Tôi cũng xin cảm ơn bạn bè, đồng nghiệp và những người đã hỗ trợ tôi trong việc trao đổi kiến thức, tìm kiếm tài liệu và đóng góp ý kiến cho đề tài. Những sự giúp đỡ đó, dù nhỏ hay lớn, đều có ý nghĩa thiết thực và giúp tôi rút ra nhiều bài học bổ ích cho quá trình học tập cũng như các hướng nghiên cứu trong tương lai.

Mặc dù đã cố gắng hoàn thiện khóa luận một cách nghiêm túc, tôi hiểu rằng đề tài vẫn khó tránh khỏi những thiếu sót. Tôi rất mong nhận được sự góp ý của quý thầy cô và các bạn để khóa luận được hoàn thiện hơn.

Một lần nữa, tôi xin chân thành cảm ơn tất cả mọi người.

Thừa Thiên Huế, tháng 6 năm 2026

Sinh viên

Hoàng Kim Thiên

Lời cam đoan

Tôi xin cam đoan khóa luận tốt nghiệp này là công trình nghiên cứu do tôi tự thực hiện dưới sự hướng dẫn của TS. Lê Quang Chiến. Các nội dung nghiên cứu, số liệu, kết quả thực nghiệm và nhận xét trình bày trong khóa luận là trung thực, được thực hiện trong quá trình học tập và nghiên cứu của bản thân.

Những tài liệu, số liệu, hình ảnh, công trình nghiên cứu và kết quả của các tác giả khác được sử dụng trong khóa luận đều được trích dẫn và ghi rõ nguồn gốc theo đúng quy định. Các phần mềm, thư viện và mã nguồn được sử dụng trong quá trình thực hiện đề tài đều được khai thác phục vụ mục đích học tập, nghiên cứu và tuân thủ các điều kiện sử dụng tương ứng.

Tôi xin chịu hoàn toàn trách nhiệm trước Nhà trường và Khoa về tính trung thực của khóa luận. Nếu phát hiện có bất kỳ hành vi gian lận, sao chép hoặc vi phạm quy định học thuật nào, tôi xin chấp nhận mọi hình thức xử lý theo quy định hiện hành.

Thừa Thiên Huế, tháng 6 năm 2026

Sinh viên

Hoàng Kim Thiên

Tóm tắt khóa luận

Khóa luận nghiên cứu bài toán tối ưu hóa mô hình nhận dạng khuôn mặt trong điều kiện lượng tử hóa 6-bit (Q6), hướng đến mục tiêu giảm chi phí lưu trữ và suy luận nhưng vẫn duy trì chất lượng embedding ở các giao thức xác minh nghiêm ngặt. Trọng tâm của khóa luận là phục hồi hiệu năng cho student Q6 thông qua sự dẫn dắt của teacher full-precision, thay vì phụ thuộc vào dữ liệu tổng hợp quy mô lớn.

Các thành quả chính đạt được gồm: xây dựng quy trình lượng tử hóa Q6 cho mô hình nhận dạng khuôn mặt; đề xuất hàm mất mát β -MSE nhằm tăng cường tín hiệu căn chỉnh embedding giữa teacher và student; thiết kế chiến lược huấn luyện ba pha gồm warm-up, đóng băng observer và cool-down để ổn định scale, zero-point và quá trình tối ưu; đồng thời xây dựng tập dữ liệu thực tế tinh lọc khoảng 53.500 ảnh từ CASIA-WebFace, VGGFace2 và IMDB-WIKI theo hướng “quality over quantity”.

Kết quả thực nghiệm trên các kiến trúc iResNet-18, iResNet-50 và MobileFaceNet cho thấy phương pháp đề xuất giúp cải thiện rõ rệt so với PTQ, đặc biệt ở chỉ số $\text{TAR@FAR}=10^{-4}$ trên các benchmark khó như CFP-FP và AgeDB-30. Với lượng dữ liệu huấn luyện nhỏ hơn đáng kể so với các hướng dùng dữ liệu tổng hợp quy mô lớn, mô hình Q6 vẫn đạt kết quả cạnh tranh trên LFW, CFP-FP, AgeDB-30, CALFW và CPLFW. Khi chuẩn hóa cùng batch size, phương pháp đề xuất cần khoảng 3.135 iteration để hoàn tất fine-tuning, trong khi hướng huấn luyện quy mô lớn như QuantFace cần khoảng 180.000 iteration; tương ứng tốc độ hội tụ được rút ngắn khoảng 57,4 lần. Ngoài ra, mô hình iResNet-18 Q6 với lịch huấn luyện ba pha đạt $\text{TAR@FAR}=10^{-4}$ là 87.900% trên AgeDB-30, vượt teacher FP32 84.967% và tương ứng recovery rate xấp xỉ 102%. Các kết quả này cho thấy phương pháp không chỉ phục hồi phần lớn suy giảm do lượng tử hóa mà còn có khả năng cải thiện độ bền vững của embedding trong một số điều kiện đánh giá khó. Các phân tích trong khóa luận cũng cho thấy việc đóng băng observer và lựa chọn hệ số β phù hợp có vai trò quan trọng trong việc giảm nhiễu lượng tử hóa và bảo toàn hình học không gian embedding.

Nhìn chung, khóa luận chứng minh rằng việc kết hợp điều phối gradient, căn chỉnh embedding và dữ liệu thực tế được tinh lọc có thể là một hướng tiếp cận hiệu quả cho nhận dạng khuôn mặt low-bit. Phương pháp này có tiềm năng hỗ trợ triển khai mô hình nhận dạng khuôn mặt trên các hệ thống tài nguyên hạn chế, đồng thời mở ra các hướng

ngiên cứu tiếp theo như mở rộng xuống 4-bit, tự động lựa chọn dữ liệu khó và đánh giá trực tiếp trên phần cứng biên.

Mục lục

1	Lời mở đầu	1
1.1	Bối cảnh và động lực	1
1.2	Vấn đề nghiên cứu	2
1.3	Mục tiêu nghiên cứu	2
1.4	Phương pháp nghiên cứu	3
1.5	Đóng góp chính	4
1.6	Phạm vi và giới hạn	4
1.7	Bố cục khóa luận	5
2	Cơ sở lý thuyết	6
2.1	Kỹ thuật nén mô hình	6
2.1.1	Kỹ thuật lượng tử hóa	6
2.1.2	Chưng cất tri thức (Knowledge Distillation)	12
2.2	Calibration (Hiệu chuẩn mô hình)	15
2.2.1	Tổng quan về độ tin cậy của mô hình	15
2.2.2	Các chỉ số đo lường calibration	15
2.2.3	Calibration trong lượng tử hóa và Knowledge Distillation	17
2.3	Nhận dạng khuôn mặt và không gian embedding	18
2.3.1	Tổng quan bài toán nhận dạng khuôn mặt	18
2.3.2	Không gian embedding trong nhận dạng khuôn mặt	18
2.4	Kiến trúc mạng nơ-ron tích chập ResNet và iResNet	20
2.4.1	Vấn đề thoái hóa trong mạng sâu	20
2.4.2	Cơ chế học thặng dư	20
2.4.3	Kiến trúc ResNet-18 và iResNet-18	21
3	Phương pháp đề xuất	24
3.1	Quy trình tổng thể	24

3.2	Khung lượng tử hóa Q6	25
3.3	Điều phối gradient bằng β -MSE	26
3.4	Chiến lược huấn luyện ba pha	26
3.4.1	Pha 1: Warm-up	28
3.4.2	Pha 2: Freeze observers	28
3.4.3	Pha 3: Fine-tuning	28
3.5	Chiến lược dữ liệu tinh lọc	29
4	Thực nghiệm, phân tích và thảo luận	32
4.1	Thiết lập thí nghiệm	32
4.2	Kết quả baseline: FP32 và Q6 PTQ	33
4.3	Tối ưu hóa siêu tham số β	34
4.4	Đánh giá tính robustness	35
4.5	Hiệu quả của việc đóng băng observer	37
4.6	So sánh với các nghiên cứu liên quan	38
4.6.1	Phân tích hiện tượng iResNet-50 wo-3p vượt teacher trên CPLFW .	39
4.6.2	Recovery rate và mức độ bảo toàn tri thức	40
4.6.3	Relative gap và so sánh công bằng giữa các giao thức	41
4.7	Phân tích tốc độ hội tụ	42
4.8	Phân tích về lưu trữ thực tế	43
4.9	Kết luận	44
4.10	Hạn chế và hướng phát triển	44
A	Thí nghiệm bổ sung với iResNet-18 trên CIFAR-10	46
A.1	Phân tích nhầm lẫn lớp Bird và Dog dưới lượng tử hóa	47
A.2	Trực quan hóa không gian đặc trưng bằng t-SNE	48

Danh sách hình vẽ

2.1	Minh họa kỹ thuật lượng tử hóa	7
2.2	So sánh lượng tử hóa đồng đều và phi tuyến.	9
2.3	Minh họa quá trình xây dựng lookup table học được cho lượng tử hóa 2-bit activation [34].	10
2.4	Khung Teacher–Student tổng quát trong chưng cất tri thức [7].	12
2.5	Kiến trúc chưng cất tri thức benchmark dựa trên soft targets và temperature softmax [12, 7].	14
2.6	Ảnh hưởng của độ sâu, độ rộng, Batch Normalization và Weight Decay đến sai lệch calibration, đo bằng ECE [8].	16
2.7	Động lực của calibration transfer qua Knowledge Distillation [11].	17
2.8	Pipeline tổng quát của một hệ thống nhận dạng khuôn mặt hiện đại. . . .	19
2.9	Sơ đồ khối residual cơ bản trong ResNet	21
2.10	Sơ đồ kiến trúc ResNet-18	22
3.1	Tổng quan phương pháp đề xuất	25
3.2	Sơ đồ luồng dữ liệu trong chiến lược huấn luyện ba pha.	27
3.3	Các mẫu ảnh tiêu biểu trong tập dữ liệu tinh lọc.	30
4.1	So sánh bản đồ Grad-CAM giữa mô hình FP32 và student Q6 trên các cặp ảnh AgeDB-30.	37
A.1	So sánh confusion matrix giữa Q8 và Q6 trên CIFAR-10.	48
A.2	So sánh t-SNE giữa FP32 và Q6 trên CIFAR-10.	49

Danh sách bảng

2.1	So sánh ba loại hàm lượng tử hóa	10
2.2	So sánh Post-Training Quantization (PTQ) và Quantization-Aware Training (QAT)	12
2.3	So sánh ResNet-18 truyền thống và iResNet-18 trong bài toán nhận dạng khuôn mặt Q6.	22
3.1	Thống kê định lượng các thành phần dữ liệu tinh lọc.	30
4.1	Baseline FP32 và Q6 PTQ: accuracy và TAR@FAR= 10^{-4}	33
4.2	So sánh accuracy (%) khi thay đổi hệ số β	34
4.3	So sánh TAR@FAR= 10^{-4} sau 30 epochs với lịch 5–20–5 khi thay đổi β	35
4.4	Đánh giá robustness bằng TAR@FAR= 10^{-4}	36
4.5	So sánh Accuracy (Q6) giữa các kiến trúc và benchmark.	39
4.6	So sánh TAR@FAR= 10^{-4} (Q6) giữa các kiến trúc và benchmark.	39
4.7	Recovery rate khi dùng CASIA-1k và CASIA-1k kết hợp dữ liệu tinh lọc.	40
4.8	Relative Gap theo TAR@FAR= 10^{-4} trên các benchmark.	41
4.9	So sánh chi phí hội tụ sau khi chuẩn hóa về batch size 512.	43
A.1	Accuracy của iResNet-18 trên CIFAR-10	47

Chương 1

Lời mở đầu

1.1 Bối cảnh và động lực

Nhận dạng khuôn mặt là một trong những bài toán quan trọng của thị giác máy tính, được ứng dụng rộng rãi trong xác thực người dùng, kiểm soát truy cập, giám sát an ninh và các hệ thống trí tuệ nhân tạo triển khai tại biên. Sự phát triển của các kiến trúc mạng sâu như iResNet cùng với các hàm mất mát biên góc như ArcFace và CosFace đã giúp mô hình nhận dạng khuôn mặt đạt độ chính xác rất cao trên nhiều bộ đánh giá chuẩn [10, 5, 33]. Các mô hình này học một không gian embedding có tính phân biệt mạnh, trong đó các ảnh cùng danh tính được kéo gần nhau, còn các ảnh khác danh tính được tách xa nhau.

Tuy nhiên, độ chính xác cao thường đi kèm với chi phí tính toán và bộ nhớ lớn. Khi triển khai trên các thiết bị tài nguyên hạn chế như điện thoại di động, camera thông minh, thiết bị IoT hoặc các nền tảng Edge AI, mô hình full-precision 32-bit có thể gây ra độ trễ cao, tiêu thụ nhiều bộ nhớ và khó đáp ứng yêu cầu thời gian thực. Vì vậy, nén mô hình trở thành một hướng nghiên cứu cần thiết để đưa các hệ thống nhận dạng khuôn mặt từ môi trường máy chủ xuống các thiết bị biên.

Trong số các kỹ thuật nén mô hình, lượng tử hóa là một hướng tiếp cận hiệu quả vì có thể giảm số bit biểu diễn trọng số và kích hoạt, từ đó giảm dung lượng lưu trữ, băng thông bộ nhớ và chi phí suy luận [17, 18, 3]. Đặc biệt, lượng tử hóa 6-bit (Q6) có tiềm năng tạo ra mô hình gọn nhẹ hơn đáng kể so với FP32. Tuy vậy, nhận dạng khuôn mặt là bài toán nhạy cảm với sai lệch nhỏ trong không gian embedding. Nhiều lượng tử hóa có thể làm méo hình học biểu diễn, làm giảm tính compact trong cùng lớp và tính separable giữa các lớp. Hệ quả là accuracy trung bình có thể vẫn tương đối ổn định, nhưng các chỉ số nghiêm ngặt hơn như TAR@FAR= 10^{-4} lại suy giảm mạnh.

Một số phương pháp gần đây, tiêu biểu là QuantFace [2], khai thác dữ liệu tổng hợp quy mô lớn để bù lại phần suy giảm do lượng tử hóa. Cách tiếp cận này có hiệu quả nhất định nhưng yêu cầu quy trình sinh dữ liệu phức tạp, chi phí lưu trữ và huấn luyện

lớn, đồng thời có thể phát sinh khoảng cách miền giữa dữ liệu tổng hợp và ảnh thực. Do đó, động lực của khóa luận là nghiên cứu một hướng tối ưu hóa hiệu quả hơn: thay vì phụ thuộc vào dữ liệu tổng hợp quy mô lớn, mô hình Q6 được dẫn dắt bởi teacher full-precision thông qua căn chỉnh embedding và được huấn luyện trên tập dữ liệu thực tế nhỏ nhưng được tinh lọc.

Sự khác biệt này dẫn đến một 'nghịch lý về tài nguyên huấn luyện' trong nghiên cứu lượng tử hóa hiện nay. Trong khi các phương pháp SOTA tiêu biểu như QuantFace [2] đòi hỏi chi phí cực lớn với quy trình sinh 500.000 ảnh tổng hợp và tiêu tốn tới 88.000 iterations (quy đổi theo cùng batch size 512) để phục hồi độ chính xác, phương pháp đề xuất trong khóa luận này chứng minh rằng có thể đạt được hiệu quả tương đương chỉ với 53.500 ảnh thực tế.

Kết quả thực nghiệm cho thấy, nhờ vào cơ chế điều phối gradient tối ưu, mô hình student Q6 đạt được sự hội tụ chỉ sau 3.135 iterations, nhanh hơn gấp 57,4 lần so với hướng tiếp cận của QuantFace [2]. Việc phá vỡ giới hạn về quy mô dữ liệu và thời gian huấn luyện này không chỉ giúp giảm thiểu rào cản về tài nguyên phần cứng mà còn đảm bảo mô hình giữ được sự ổn định trong các điều kiện thực tế khắc nghiệt nhờ học từ dữ liệu thực tinh lọc thay vì dữ liệu tổng hợp.

1.2 Vấn đề nghiên cứu

Khóa luận tập trung giải quyết hai vấn đề chính trong tối ưu hóa mô hình nhận dạng khuôn mặt 6-bit:

- **Sự suy giảm hiệu năng ở ngưỡng xác thực nghiêm ngặt:** Khi mô hình nhận dạng khuôn mặt được lượng tử hóa xuống 6-bit, sai số lượng tử hóa có thể làm lệch không gian embedding. Sự lệch này đặc biệt ảnh hưởng đến $TAR@FAR=10^{-4}$, chỉ số quan trọng trong các hệ thống xác thực yêu cầu tỷ lệ chấp nhận nhầm rất thấp.
- **Sự phụ thuộc vào dữ liệu tổng hợp quy mô lớn:** Các phương pháp như QuantFace sử dụng lượng lớn dữ liệu tổng hợp để phục hồi hiệu năng sau lượng tử hóa [2]. Tuy nhiên, cách làm này tiêu tốn tài nguyên sinh dữ liệu, lưu trữ và huấn luyện, đồng thời có nguy cơ tạo ra khoảng cách miền so với dữ liệu thực tế.

Từ hai vấn đề trên, câu hỏi nghiên cứu đặt ra là: liệu có thể phục hồi hiệu năng của mô hình nhận dạng khuôn mặt Q6, đặc biệt là $TAR@FAR=10^{-4}$, bằng một chiến lược huấn luyện ổn định hơn và một tập dữ liệu thực tế được chọn lọc kỹ, thay vì dựa vào dữ liệu tổng hợp quy mô lớn hay không?

1.3 Mục tiêu nghiên cứu

Các mục tiêu chính của khóa luận bao gồm:

- **Xây dựng quy trình huấn luyện nhận biết lượng tử (QAT) 6-bit:** Mô phỏng đồng thời sai số lượng tử hóa của cả trọng số và kích hoạt dưới ràng buộc Q6 ngay trong quá trình huấn luyện để mô hình student thích nghi với dải giá trị rời rạc.
- **Đề xuất cơ chế điều phối gradient thông qua hàm mất mát β -MSE:** Tập trung vào việc bảo toàn cấu trúc hình học của không gian Embedding nhằm ngăn chặn sự biến dạng đa tạp đặc trưng do nhiễu lượng tử hóa gây ra. Qua đó, mục tiêu cốt lõi là duy trì hiệu suất trích xuất đặc trưng tại các ngưỡng xác thực nghiêm ngặt, đảm bảo chỉ số TAR không bị sụt giảm tại $FAR = 10^{-4}$.
- **Thúc đẩy sự hội tụ nhanh chóng với chiến lược huấn luyện ba pha:** Thiết lập lịch trình gồm warm-up, đóng băng observer và cool-down nhằm ổn định dải lượng tử và giảm dao động tối ưu. Qua đó, chứng minh rằng việc sử dụng số lượng vòng lặp huấn luyện ít hơn đáng kể vẫn đủ để đạt hiệu quả phục hồi tri thức tiệm cận mô hình gốc.
- **Phá vỡ sự phụ thuộc vào dữ liệu khổng lồ với chiến lược “Quality over Quantity”:** Xây dựng tập dữ liệu thực tế tinh lọc khoảng 53.500 ảnh từ các nguồn CASIA-WebFace, VGGFace2 và IMDB-WIKI [35, 4, 27]. Mục tiêu là chứng minh rằng dữ liệu thực có biến thiên cao về tư thế (pose) và độ tuổi (age) có thể thay thế hiệu quả cho hàng trăm nghìn ảnh tổng hợp trong việc phục hồi tri thức.
- **Đánh giá tính toàn diện và khả năng phục hồi (Recovery Rate):** Kiểm chứng hiệu quả của phương pháp trên đa dạng kiến trúc (iResNet-18, iResNet-50, MobileFaceNet) và các benchmark chuẩn gồm LFW, CFP-FP, AgeDB-30, CALFW và CPLFW [14, 30, 22, 39, 38] nhằm chứng minh khả năng phục hồi hiệu năng tiệm cận hoặc vượt qua mô hình Teacher full-precision.

1.4 Phương pháp nghiên cứu

Để đạt được các mục tiêu trên, khóa luận sử dụng các phương pháp nghiên cứu sau:

- **Nghiên cứu lý thuyết:** Tìm hiểu các nền tảng liên quan đến nhận dạng khuôn mặt, embedding học sâu, lượng tử hóa mô hình, QAT, chứng cất tri thức và hiệu chuẩn lượng tử hóa.
- **Đề xuất mô hình tối ưu hóa:** Xây dựng hàm mục tiêu β -MSE để tăng cường tín hiệu căn chỉnh embedding giữa teacher và student. Hệ số β được sử dụng để khuếch đại gradient căn chỉnh, giúp student Q6 bám sát không gian biểu diễn của teacher.
- **Thiết kế quy trình huấn luyện:** Áp dụng lịch huấn luyện ba pha nhằm tách quá trình thích nghi ban đầu, ổn định dải lượng tử và tinh chỉnh cuối cùng. Việc đóng băng observer được dùng để cố định scale và zero-point sau khi đã thu thập đủ thống kê kích hoạt.

- **Thực nghiệm và đánh giá:** Huấn luyện và đánh giá mô hình trên nhiều kiến trúc như iResNet-18, iResNet-50 và MobileFaceNet, sử dụng các chỉ số accuracy và $\text{TAR@FAR}=10^{-4}$ để phản ánh cả độ chính xác tổng thể lẫn khả năng hoạt động ở ngưỡng bảo mật cao.

1.5 Đóng góp chính

Khóa luận có các đóng góp chính sau:

- Đề xuất hàm mục tiêu β -MSE cho bài toán lượng tử hóa nhận dạng khuôn mặt 6-bit, giúp tăng cường tín hiệu căn chỉnh embedding giữa teacher full-precision và student Q6.
- Xây dựng chiến lược huấn luyện ba pha gồm warm-up, đóng băng observer và cool-down nhằm ổn định tối ưu hóa trong điều kiện lượng tử hóa thấp bit.
- Chứng minh rằng tập dữ liệu thực tế tinh lọc khoảng 53.500 ảnh có thể hỗ trợ phục hồi hiệu năng hiệu quả, thay vì phụ thuộc vào dữ liệu tổng hợp quy mô lớn.
- Đánh giá thực nghiệm trên nhiều benchmark và nhiều kiến trúc, cho thấy phương pháp có khả năng cải thiện đáng kể $\text{TAR@FAR}=10^{-4}$, đồng thời đạt tốc độ hội tụ nhanh hơn so với hướng dùng dữ liệu quy mô lớn.

1.6 Phạm vi và giới hạn

- **Về mô hình:** Khóa luận tập trung vào các kiến trúc nhận dạng khuôn mặt phổ biến như iResNet-18, iResNet-50 và MobileFaceNet. Nghiên cứu không đề xuất kiến trúc mạng mới, mà tập trung vào tối ưu hóa quá trình lượng tử hóa và huấn luyện student Q6.
- **Về mức lượng tử hóa:** Trọng tâm của khóa luận là lượng tử hóa 6-bit cho trọng số và kích hoạt. Các mức thấp hơn như 4-bit chưa được khảo sát sâu trong phạm vi nghiên cứu này.
- **Về dữ liệu:** Tập huấn luyện được xây dựng từ dữ liệu thực tế tinh lọc gồm CASIA-1k, tập con pose từ VGGFace2 và tập con age từ IMDB-WIKI. Khóa luận không tập trung vào sinh dữ liệu tổng hợp hoặc mở rộng quy mô dữ liệu lên hàng trăm nghìn đến hàng triệu ảnh.
- **Về đánh giá:** Nghiên cứu đánh giá trên các benchmark chuẩn LFW, CFP-FP, AgeDB-30, CALFW và CPLFW. Việc triển khai và đo tốc độ suy luận trên phần cứng Edge AI thực tế được xem là hướng phát triển tiếp theo.

1.7 Bố cục khóa luận

Ngoài phần lời mở đầu, khóa luận được tổ chức thành bốn chương nội dung chính như sau:

- **Chương 1: Cơ sở lý thuyết:** Giới thiệu các nền tảng liên quan đến nén mô hình, lượng tử hóa, chứng cất tri thức, hiệu chuẩn mô hình và nhận dạng khuôn mặt.
- **Chương 2: Phương pháp đề xuất:** Mô tả quy trình lượng tử hóa Q6, hàm mục tiêu β -MSE, chiến lược huấn luyện ba pha và chiến lược dữ liệu tinh lọc.
- **Chương 3: Thực nghiệm và kết quả:** Trình bày thiết lập thí nghiệm, kết quả baseline, ảnh hưởng của hệ số β , phân tích tốc độ hội tụ và kết quả tổng hợp trên các benchmark.
- **Chương 4: Phân tích, thảo luận và kết luận:** Phân tích vai trò của observer freezing, so sánh với các nghiên cứu liên quan, thảo luận hạn chế và đề xuất hướng phát triển tiếp theo.

Chương 2

Cơ sở lý thuyết

2.1 Kỹ thuật nén mô hình


Sự phát triển mạnh mẽ của các mô hình học sâu trong thập kỷ qua đã mang lại những bước tiến vượt bậc về hiệu suất trong nhiều lĩnh vực, bao gồm cả nhận dạng khuôn mặt. Tuy nhiên, hiệu suất cao thường đi kèm với độ phức tạp lớn, số lượng tham số nhiều và chi phí tính toán cũng như bộ nhớ cao [10]. Điều này gây ra nhiều hạn chế khi triển khai các mô hình trên thiết bị di động, hệ thống nhúng hoặc môi trường có tài nguyên hạn chế, nơi người dùng kỳ vọng ứng dụng phản hồi nhanh và tiêu thụ năng lượng thấp [3].

Trong bối cảnh đó, các kỹ thuật nén mô hình được nghiên cứu nhằm giảm kích thước và chi phí tính toán của mạng nơ-ron mà vẫn duy trì hiệu suất nhận dạng ở mức chấp nhận được. Hai kỹ thuật nén nổi bật liên quan trực tiếp đến khóa luận này là **lượng tử hóa (quantization)** và **chưng cất tri thức (knowledge distillation)**. Lượng tử hóa tập trung vào việc giảm độ chính xác biểu diễn của trọng số và kích hoạt xuống số nguyên low-bit, giúp giảm dung lượng lưu trữ và tăng tốc độ suy luận. Trong khi đó, chưng cất tri thức cho phép mô hình nhỏ hoặc mô hình bị ràng buộc tài nguyên học từ mô hình lớn hơn, từ đó duy trì hiệu năng tốt hơn so với việc tối ưu độc lập.

2.1.1 Kỹ thuật lượng tử hóa

Các mô hình nhận dạng khuôn mặt hiện đại thường có số lượng tham số lớn và yêu cầu lưu trữ trọng số, kích hoạt ở định dạng dấu phẩy động 32-bit (FP32). Điều này giúp mô hình đạt độ chính xác cao nhưng làm tăng chi phí bộ nhớ và tính toán, đặc biệt khi triển khai trên thiết bị biên [5, 3]. Lượng tử hóa giải quyết vấn đề này bằng cách ánh xạ các giá trị FP32 sang miền số nguyên có độ chính xác thấp hơn, ví dụ 8-bit hoặc 6-bit. Hình 2.1 minh họa trực quan ý tưởng giảm số bit biểu diễn trong lượng tử hóa.

Theo Krishnamoorthi, việc chuyển mô hình từ FP32 sang 8-bit có thể giúp giảm kích thước lưu trữ xấp xỉ 4 lần trong khi độ chính xác chỉ suy giảm nhẹ đối với nhiều mạng



Hình 2.1: Minh họa kỹ thuật lượng tử hóa

CNN [18]. Tuy nhiên, khi giảm xuống mức thấp hơn như 6-bit, sai số lượng tử hóa trở nên rõ rệt hơn. Đối với nhận dạng khuôn mặt, sai số này có thể làm biến dạng không gian embedding, khiến các chỉ số ở ngưỡng xác thực nghiêm ngặt như $\text{TAR@FAR}=10^{-4}$ suy giảm mạnh.

Khi phân tích kỹ thuật lượng tử hóa, có bốn yếu tố chính cần xem xét:

- Hàm lượng tử hóa.
- Chiến lược lượng tử hóa.
- Độ mịn lượng tử hóa.
- Thuật toán toàn cục trong lượng tử hóa.

Hàm lượng tử hóa

Hàm lượng tử hóa là thành phần cốt lõi trong quá trình chuyển đổi tham số từ miền liên tục (floating-point – FP) sang miền rời rạc có độ chính xác thấp hơn (low-precision – LP). Về mặt tổng quát, quá trình này có thể biểu diễn như sau:

$$x_{LP} = \text{quantizer}(x_{FP}). \quad (2.1)$$

Tùy theo cách thiết kế hàm ánh xạ, có thể chia thành ba nhóm phổ biến: lượng tử hóa đồng đều, lượng tử hóa phi tuyến và lượng tử hóa học được.

Lượng tử hóa đồng đều (Uniform Quantization). Lượng tử hóa đồng đều là dạng phổ biến nhất nhờ tính đơn giản và khả năng triển khai hiệu quả trên phần cứng. Phương pháp này ánh xạ giá trị FP sang miền số nguyên thông qua một hệ số tỉ lệ (scale) và điểm gốc (zero-point). Các mức lượng tử được chia đều trên toàn bộ miền giá trị, vì vậy sai số lượng tử hóa phụ thuộc mạnh vào cách chọn miền $[FP_{\min}, FP_{\max}]$.

$$x_{LP} = \text{clip} \left(\text{round} \left(\frac{x_{FP}}{s} \right) + z, LP_{\min}, LP_{\max} \right), \quad (2.2)$$

trong đó s là hệ số tỉ lệ, z là zero-point, và $[LP_{\min}, LP_{\max}]$ là miền số nguyên hợp lệ. Hệ số tỉ lệ thường được tính bởi:

$$s = \frac{FP_{\max} - FP_{\min}}{LP_{\max} - LP_{\min}}, \quad (2.3)$$

trong khi zero-point được xác định xấp xỉ bằng:

$$z = \text{round} \left(\frac{-FP_{\min}}{s} \right). \quad (2.4)$$

Hàm $\text{clip}(\cdot)$ đảm bảo giá trị sau lượng tử hóa nằm trong miền số nguyên hợp lệ:

$$p_{\text{quant}} = \begin{cases} LP_{\min}, & \text{nếu } p_{\text{int}} < LP_{\min}, \\ LP_{\max}, & \text{nếu } p_{\text{int}} > LP_{\max}, \\ p_{\text{int}}, & \text{ngược lại.} \end{cases} \quad (2.5)$$

Sau khi tính toán trong miền low-bit, giá trị có thể được giải lượng tử hóa về miền FP bằng:

$$\hat{x}_{FP} \approx (x_{LP} - z) \cdot s. \quad (2.6)$$


Lượng tử hóa phi tuyến (Non-Uniform Quantization). Khác với lượng tử hóa đồng đều, lượng tử hóa phi tuyến sử dụng các bước lượng tử không đều nhằm phản ánh tốt hơn phân phối thực tế của dữ liệu. Một ví dụ điển hình là lượng tử hóa logarit, trong đó giá trị đầu vào được ánh xạ thông qua miền log:

$$x_{LP} = \text{quantizer}(\log_2(x_{FP})). \quad (2.7)$$

Phương pháp này có khả năng nén dải động của dữ liệu, tăng độ phân giải ở vùng giá trị nhỏ và giảm độ phân giải ở vùng giá trị lớn. Điều này phù hợp với các tensor có phân phối lệch hoặc dải giá trị rộng. Hình 2.2 so sánh trực tiếp uniform quantization và non-uniform quantization: uniform quantization chia đều miền giá trị, trong khi non-uniform quantization bố trí nhiều mức lượng tử hơn ở vùng dữ liệu tập trung, nhờ đó có thể giảm sai số biểu diễn trong các vùng quan trọng của phân phối.

Biểu diễn logarit còn giúp thay thế một số phép nhân bằng cộng và dịch bit, từ đó giảm độ phức tạp phần cứng [21]. Với hai vector w và x , tích vô hướng có thể được xấp xỉ trong miền log như sau:

$$w^T x \approx \sum_{i=1}^n \text{Bitshift}(1, \tilde{w}_i + \tilde{x}_i) = \sum_{i=1}^n 2^{p_i}, \quad (2.8)$$



Hình 2.2: So sánh lượng tử hóa đồng đều và phi tuyến.

trong đó $p_i = \tilde{w}_i + \tilde{x}_i$. Khi cộng hai phần tử trong miền log, ta có:

$$S_2 = \log_2(2^{p_1} + 2^{p_2}) = \max(p_1, p_2) + \log_2(1 + 2^{-|p_1 - p_2|}). \quad (2.9)$$

Biểu thức này có thể xấp xỉ bằng các phép so sánh và dịch bit, phù hợp hơn cho triển khai phần cứng.

Lượng tử hóa học được (Learnable Quantization). Lượng tử hóa học được xem các mức lượng tử như tham số có thể tối ưu, thay vì cố định trước theo công thức uniform hoặc log. Wang và cộng sự đề xuất mô hình hóa quá trình lượng tử hóa bằng Lookup Table (LUT), trong đó các mức lượng tử được học cùng mạng nơ-ron theo cơ chế end-to-end [34]. Cách tiếp cận này cho phép LUT thích ứng với phân phối của từng layer, nhờ đó giảm lỗi lượng tử hóa và duy trì độ chính xác tốt hơn. Hình 2.3 minh họa quá trình xây dựng LUT học được: hàm lượng tử hóa ban đầu được biểu diễn dưới dạng bảng ánh xạ, sau đó tách thành các bảng con nhị phân tương ứng với các hàm bậc thang. Trong huấn luyện, các bảng con này được chuyển sang phân phối one-hot rồi làm mềm bằng temperature softmax để có thể tối ưu bằng lan truyền ngược; khi nhiệt độ giảm, phân phối hội tụ về one-hot và LUT được làm cứng để dùng trong suy luận.


Một dạng công thức lượng tử hóa có thể viết như sau:

$$x_{LP} = s \cdot \text{quantizer} \left(\text{clip} \left(\frac{x_{FP}}{s} \right), Q \right), \quad (2.10)$$

trong đó Q là tập mức lượng tử được học. Với activation b -bit, số mức lượng tử có thể đặt là $Q_a = 2^b - 1$. Thay vì chọn mức cố định, LUT có thể dùng phân phối softmax:

$$q = \sum_{i=1}^K p_i v_i, \quad p_i = \frac{\exp(g_i/\tau)}{\sum_{j=1}^K \exp(g_j/\tau)}, \quad (2.11)$$

trong đó v_i là các mức lượng tử ứng viên, p_i là xác suất chọn mức và τ là nhiệt độ điều khiển độ sắc của phân phối. Trong huấn luyện, Straight-Through Estimator (STE) thường được dùng để truyền gradient qua bước lượng tử hóa.



Hình 2.3: Minh họa quá trình xây dựng lookup table học được cho lượng tử hóa 2-bit activation [34].

Bảng 2.1: So sánh ba loại hàm lượng tử hóa

Tiêu chí	Uniform Quantization	Log Quantization	Learnable Quantization
Nguyên lý	Chia đều khoảng giá trị thành các mức lượng tử cố định	Chia theo thang logarit, phù hợp với dữ liệu có dải động rộng	Các mức lượng tử được học trực tiếp từ dữ liệu hoặc lưu trong LUT
Ưu điểm	Đơn giản, dễ triển khai trên phần cứng	Có thể giảm lỗi với dữ liệu phân phối lệch, tận dụng dịch bit	Thích ứng tốt hơn với phân phối thực tế của từng layer
Nhược điểm	Dễ gây lỗi nếu dữ liệu có phân phối không đều	Khó triển khai đồng nhất hơn uniform	Cần huấn luyện thêm và thiết kế phức tạp hơn
Chi phí tính toán	Rất thấp	Thấp đến trung bình	Thấp khi suy luận, cao hơn khi huấn luyện

Chiến lược lượng tử hóa

Bên cạnh hàm lượng tử hóa, cần xác định đối tượng nào trong mô hình sẽ được lượng tử hóa. Có ba chiến lược phổ biến:

- **Weight-Only Quantization (WOQ):** chỉ lượng tử hóa trọng số của mô hình. Vì trọng số cố định sau huấn luyện, miền giá trị của chúng có thể xác định trước và không phụ thuộc vào dữ liệu đầu vào. Chiến lược này đơn giản, ít ảnh hưởng đến độ chính xác nhưng chỉ giảm một phần chi phí tính toán.
- **Activation-Only Quantization (AOQ):** chỉ lượng tử hóa giá trị kích hoạt. Khác với trọng số, kích hoạt phụ thuộc vào dữ liệu đầu vào, do đó thường cần tập calibration để ước lượng miền giá trị phù hợp. Nếu calibration không đại diện, sai số lượng tử hóa có thể tăng.

- **Weight-Activation Quantization (WAQ):** lượng tử hóa đồng thời cả trọng số và kích hoạt. Đây là chiến lược toàn diện nhất vì có thể giảm mạnh chi phí bộ nhớ và tính toán, nhưng cũng khó tối ưu hơn và thường cần kết hợp với Quantization-Aware Training (QAT).

Độ mịn lượng tử hóa

Độ mịn lượng tử hóa (granularity) quyết định cách nhóm tham số để xác định miền giá trị FP và hệ số scale. Việc lựa chọn granularity ảnh hưởng trực tiếp đến độ chính xác sau lượng tử hóa cũng như chi phí triển khai. Ba lựa chọn phổ biến gồm:

- **Layer-wise quantization:** mỗi lớp dùng một miền giá trị chung. Cách này đơn giản và dễ triển khai, nhưng có thể gây sai số lớn nếu các kênh trong cùng một lớp có phân phối khác biệt [40].
- **Group-wise quantization:** các kênh được chia thành nhiều nhóm, mỗi nhóm có miền giá trị riêng. Phương pháp này cân bằng giữa độ chính xác và chi phí tính toán.
- **Channel-wise quantization:** mỗi kênh được lượng tử hóa độc lập với miền giá trị riêng. Đây là cách chi tiết nhất, thường cho độ chính xác cao hơn trong các mạng có biến thiên mạnh giữa các kênh [37], nhưng cần lưu nhiều hệ số scale hơn.

Thuật toán toàn cục trong lượng tử hóa

Quy trình lượng tử hóa có thể được triển khai theo hai cách tiếp cận toàn cục: Post-Training Quantization (PTQ) và Quantization-Aware Training (QAT).

Post-Training Quantization (PTQ). PTQ là phương pháp lượng tử hóa được áp dụng sau khi mô hình đã được huấn luyện đầy đủ ở độ chính xác FP32. Cách tiếp cận này đơn giản, không yêu cầu huấn luyện lại toàn bộ mô hình và phù hợp khi cần triển khai nhanh [18, 20]. Tuy nhiên, PTQ thường dẫn đến suy giảm hiệu năng, đặc biệt khi số bit giảm xuống mức thấp [15]. Nguyên nhân là mô hình không được huấn luyện để thích nghi với ràng buộc low-bit, dẫn đến mất mát thông tin trong quá trình lượng tử hóa.


Quantization-Aware Training (QAT). QAT đưa quá trình lượng tử hóa vào ngay trong giai đoạn huấn luyện. Trong QAT, các phép lượng tử hóa được mô phỏng ở lan truyền xuôi và gradient được xấp xỉ ở lan truyền ngược, thường thông qua Straight-Through Estimator (STE). Nhờ đó, mô hình học cách thích nghi với nhiễu lượng tử hóa và thường đạt hiệu năng tốt hơn PTQ ở mức low-bit [17, 15]. Đổi lại, QAT có chi phí huấn luyện cao hơn và thường yêu cầu truy cập lại dữ liệu huấn luyện.

Bảng 2.2: So sánh Post-Training Quantization (PTQ) và Quantization-Aware Training (QAT)

Tiêu chí	PTQ	QAT
Thời điểm áp dụng	Sau khi mô hình đã huấn luyện ở FP32	Trong quá trình huấn luyện, mô phỏng lượng tử hóa từ sớm
Độ phức tạp triển khai	Đơn giản, không cần huấn luyện lại toàn bộ mô hình	Phức tạp hơn, cần huấn luyện hoặc fine-tuning với dữ liệu
Chi phí tính toán	Thấp	Cao hơn do cần huấn luyện lại
Hiệu năng đạt được	Dễ suy giảm khi số bit nhỏ	Thường duy trì độ chính xác gần FP32 hơn
Yêu cầu dữ liệu	Chỉ cần dữ liệu calibration hoặc thậm chí không cần dữ liệu	Cần dữ liệu huấn luyện hoặc dữ liệu đại diện
Ứng dụng phù hợp	Triển khai nhanh, chấp nhận suy hao hiệu năng	Hệ thống yêu cầu độ chính xác cao ở mức low-bit

2.1.2 Chưng cất tri thức (Knowledge Distillation)

Chưng cất tri thức là kỹ thuật huấn luyện một mô hình nhỏ, gọi là *student*, bằng cách khai thác tín hiệu giám sát từ một mô hình lớn hơn hoặc chính xác hơn, gọi là *teacher* [12, 7]. Thay vì chỉ học từ nhãn cứng của dữ liệu huấn luyện, student còn học từ đầu ra mềm hoặc biểu diễn trung gian của teacher. Cơ chế này đặc biệt phù hợp với nén mô hình vì teacher thường đã học được cấu trúc phân biệt tinh vi của dữ liệu, trong khi student có ít tham số hơn hoặc bị ràng buộc bởi yêu cầu suy luận nhanh trên thiết bị hạn chế tài nguyên. Hình 2.4 minh họa tổng quát quá trình teacher truyền tri thức sang student thông qua một khối chuyển giao tri thức.



Hình 2.4: Khung Teacher-Student tổng quát trong chưng cất tri thức [7].

Cơ chế Teacher–Student. Với một mẫu đầu vào x , teacher và student lần lượt sinh ra logits z_t và z_s , hoặc embedding $f_t(x)$ và $f_s(x)$. Teacher thường được giữ cố định trong quá trình huấn luyện student. Nhiệm vụ của student không chỉ là dự đoán đúng nhãn thật y , mà còn bắt chước phân phối đầu ra hoặc không gian biểu diễn của teacher. Trong bài toán nhận dạng khuôn mặt, mục tiêu cuối cùng là học embedding có khả năng tách biệt danh tính tốt; do đó, chùng cất tại tầng embedding có ý nghĩa trực tiếp vì nó giúp student bảo toàn hình học cosine mà teacher đã học được [5, 33].

Hàm mất mát MSE. Mean Squared Error (MSE) thường được dùng khi muốn student bắt chước trực tiếp embedding hoặc feature map của teacher. Nếu $f_t(x)$ và $f_s(x)$ là hai vector embedding đã được chuẩn hóa, loss MSE có thể viết như sau:

$$\mathcal{L}_{\text{MSE}} = \frac{1}{d} \|f_s(x) - f_t(x)\|_2^2, \quad (2.12)$$

trong đó d là số chiều embedding. Loss này khuyến khích student tạo ra biểu diễn gần với teacher trong không gian đặc trưng, nhờ đó giảm nguy cơ nhiễu lượng tử hóa hoặc giới hạn dung lượng mô hình làm biến dạng quan hệ giữa các khuôn mặt. Các phương pháp như FitNets cũng mở rộng ý tưởng này bằng cách dùng biểu diễn trung gian của teacher làm tín hiệu gợi ý cho student [26].

Tuy nhiên, trong bài toán nhận dạng khuôn mặt, các vector đặc trưng f_t và f_s luôn được chuẩn hóa L_2 để nằm trên mặt cầu đơn vị trước khi tính toán độ tương đồng. Việc chuẩn hóa này dẫn đến một thách thức toán học: giá trị MSE thô giữa hai vector đã chuẩn hóa thường có biên độ cực kỳ nhỏ.

Về mặt lý thuyết, đạo hàm của hàm mất mát MSE theo tham số mạng tỉ lệ thuận với sai khác giữa các vector đặc trưng. Khi giá trị MSE thô quá nhỏ, tín hiệu Gradient sinh ra không đủ mạnh để “dẫn dắt” mô hình Student Q6 thích nghi và sửa lỗi trước các nhiễu rời rạc hóa do lượng tử hóa gây ra. Hệ quả là Student dễ bị “trôi” khỏi không gian biểu diễn của Teacher, làm biến dạng cấu trúc hình học của không gian Embedding và gây sụt giảm nghiêm trọng chỉ số TAR tại các ngưỡng FAR thấp.

Để giải quyết vấn đề này, khái niệm “Điều phối Gradient” (Gradient Coordination) được đề xuất thông qua việc sử dụng hệ số khuếch đại β lớn trong hàm mất mát β -MSE. Về bản chất toán học, β đóng vai trò là một bộ nhân tỉ lệ (scaling factor) cho tín hiệu Gradient:

- **Khuếch đại tín hiệu dẫn dắt:** Hệ số β giúp tăng cường “lực hút” của Student về phía đa tạp đặc trưng (feature manifold) của Teacher, buộc Student phải sửa đổi các sai lệch hướng một cách quyết liệt hơn ngay cả khi sai số Embedding là nhỏ.
- **Căn chỉnh quỹ đạo tối ưu:** Thay vì chỉ khớp kết quả tại điểm hội tụ, việc điều phối Gradient giúp kiểm soát quỹ đạo cập nhật trọng số của Student Q6 sao cho

bám sát nhất với đặc tính phân biệt danh tính của mô hình FP32 trong suốt quá trình huấn luyện.

Vì vậy, việc lựa chọn hệ số β phù hợp (thường từ 200 đến 500 tùy kiến trúc) là yếu tố then chốt để phục hồi hiệu năng mô hình low-bit mà không cần phụ thuộc vào lượng dữ liệu khổng lồ.

Để người đọc có cái nhìn trực quan về cách hàm mục tiêu này được tích hợp vào luồng xử lý và tối ưu hóa mô hình, vị trí của thành phần căn chỉnh embedding β -MSE trong quy trình tổng thể của đề xuất được trình bày chi tiết tại Hình 3.1 (Chương 3). Việc tham chiếu trước đến sơ đồ này sẽ giúp làm rõ vai trò của điều phối gradient trong việc trực tiếp dẫn dắt mô hình Student Q6 bám sát đa tạp đặc trưng của Teacher.


Hàm mất mát KL-Divergence. KL-Divergence thường được dùng khi student học từ phân phối xác suất sau softmax của teacher. Để làm nổi bật quan hệ giữa các lớp, logits được chia cho nhiệt độ T trước khi áp dụng softmax:

$$p_t^{(T)} = \text{softmax} \left(\frac{z_t}{T} \right), \quad p_s^{(T)} = \text{softmax} \left(\frac{z_s}{T} \right). \quad (2.13)$$

Khi đó, loss chưng cất được tính bởi:

$$\mathcal{L}_{\text{KL}} = T^2 \sum_i p_{t,i}^{(T)} \log \frac{p_{t,i}^{(T)}}{p_{s,i}^{(T)}}. \quad (2.14)$$

Hệ số T^2 thường được dùng để cân bằng độ lớn gradient khi thay đổi nhiệt độ [12]. Với $T > 1$, phân phối của teacher trở nên mềm hơn, giúp student học được thông tin về mức độ tương đồng giữa các lớp thay vì chỉ học nhãn đúng/sai. Hình 2.5 thể hiện kiến trúc chưng cất kinh điển của Hinton và cộng sự: teacher tạo soft targets ở nhiệt độ $T = t$, student học đồng thời từ soft targets và nhãn thật để cân bằng giữa tri thức mềm và tín hiệu giám sát trực tiếp.



Hình 2.5: Kiến trúc chưng cất tri thức benchmark dựa trên soft targets và temperature softmax [12, 7].

Trong thực tế, loss huấn luyện student thường kết hợp loss nhãn thật và loss chưng cất:

$$\mathcal{L}_{\text{total}} = \alpha \mathcal{L}_{\text{CE}}(y, p_s) + \beta \mathcal{L}_{\text{KL}} + \gamma \mathcal{L}_{\text{MSE}}, \quad (2.15)$$

trong đó α , β và γ điều khiển mức đóng góp của từng thành phần. Đối với mô hình nhận dạng khuôn mặt lượng tử hóa thấp bit, thành phần MSE ở embedding giúp giữ ổn định hình học biểu diễn, trong khi KL-Divergence ở logits hoặc lớp phân loại giúp student duy trì thông tin phân biệt danh tính từ teacher. Vì vậy, chứng cất tri thức thường được xem là kỹ thuật bổ trợ quan trọng cho lượng tử hóa khi cần giảm kích thước mô hình nhưng vẫn duy trì độ chính xác xác minh ở các ngưỡng FAR nghiêm ngặt.

2.2 Calibration (Hiệu chuẩn mô hình)

2.2.1 Tổng quan về độ tin cậy của mô hình

Trong các hệ thống học sâu, accuracy thường được xem là chỉ số tối ưu hóa chính. Tuy nhiên, với các ứng dụng có yêu cầu an toàn cao như chẩn đoán y tế, xe tự lái hoặc xác minh danh tính, mô hình không chỉ cần dự đoán đúng mà còn cần ước lượng đúng mức độ tin cậy của chính dự đoán đó. Một mô hình có accuracy cao nhưng quá tự tin khi dự đoán sai vẫn có thể gây rủi ro trong triển khai thực tế [8, 25].

Định nghĩa calibration. Một mô hình được gọi là calibrated hoàn hảo nếu xác suất dự đoán (confidence) phản ánh đúng tần suất chính xác trong thực tế. Với nhãn dự đoán $\hat{Y}$, nhãn thật Y , và độ tin cậy dự đoán $\hat{P}$, điều kiện calibration có thể viết là:

$$\mathbb{P}(\hat{Y} = Y \mid \hat{P} = p) = p. \quad (2.16)$$

Ví dụ, trong tập các mẫu mà mô hình dự đoán với confidence xấp xỉ 0.8, khoảng 80% dự đoán nên đúng nếu mô hình được hiệu chuẩn tốt.

Hiện tượng overconfidence. Các mạng nơ-ron sâu hiện đại thường có xu hướng overconfident, tức là gán xác suất cao cho cả các dự đoán sai. Guo và cộng sự cho thấy các yếu tố như độ sâu mạng, Batch Normalization và Weight Decay có thể làm tăng sai lệch calibration mặc dù accuracy vẫn cao [8]. Trong bối cảnh lượng tử hóa thấp bit, nhiều do làm tròn và clipping có thể làm phân phối logits hoặc embedding thay đổi, khiến confidence của mô hình không còn phản ánh chính xác độ tin cậy thực tế. Vì vậy, đánh giá calibration là bổ sung cần thiết cho accuracy và TAR@FAR.

2.2.2 Các chỉ số đo lường calibration


Expected Calibration Error (ECE)

Expected Calibration Error (ECE) là thước đo phổ biến để định lượng mức độ sai lệch giữa accuracy và confidence [23, 8]. Cách tính thường chia khoảng xác suất $[0, 1]$ thành M bin rời rạc. Gọi B_m là tập mẫu rơi vào bin thứ m , n là tổng số mẫu, $\text{acc}(B_m)$ là

độ chính xác thực tế trong bin và $\text{conf}(B_m)$ là confidence trung bình trong bin. Khi đó:

$$\text{ECE} = \sum_{m=1}^M \frac{|B_m|}{n} |\text{acc}(B_m) - \text{conf}(B_m)|. \quad (2.17)$$

Nếu ECE nhỏ, confidence của mô hình gần với tần suất đúng thực tế. Ngược lại, ECE lớn cho thấy mô hình đang underconfident hoặc overconfident ở một số vùng confidence.



Hình 2.6: Ảnh hưởng của độ sâu, độ rộng, Batch Normalization và Weight Decay đến sai lệch calibration, đo bằng ECE [8].

Hình 2.6 cho thấy error và ECE không luôn biến thiên cùng chiều. Khi tăng độ sâu hoặc độ rộng của mạng, error có xu hướng giảm nhưng ECE vẫn có thể tăng hoặc duy trì ở mức cao, nghĩa là mô hình chính xác hơn nhưng xác suất dự đoán chưa chắc phản ánh đúng tần suất chính xác thực tế. Ngoài ra, Batch Normalization và Weight Decay cũng làm thay đổi ECE, cho thấy calibration chịu ảnh hưởng bởi cả kiến trúc lẫn cơ chế huấn luyện. Vì vậy, trong đánh giá mô hình nén hoặc mô hình lượng tử hóa, accuracy cần được xem xét cùng với các chỉ số calibration như ECE.

Class-conditional ECE

ECE tổng thể có thể che khuất sai lệch calibration theo từng lớp, đặc biệt khi dữ liệu mất cân bằng hoặc một số lớp khó phân biệt hơn các lớp còn lại. Nixon và cộng sự nhấn mạnh rằng việc đo calibration theo lớp giúp phát hiện các trường hợp mô hình đáng tin cậy ở một số lớp nhưng lại quá tự tin ở các lớp khác [25]. Với mỗi lớp c , có thể tính ECE riêng trên các mẫu được dự đoán hoặc gán nhãn thuộc lớp đó:


$$\text{ECE}_c = \sum_{m=1}^M \frac{|B_{m,c}|}{n_c} |\text{acc}(B_{m,c}) - \text{conf}(B_{m,c})|. \quad (2.18)$$

Trong nhận dạng khuôn mặt, cách nhìn theo lớp hoặc theo nhóm dữ liệu cũng hữu ích vì các nhóm khó như ảnh nghiêng, ảnh mờ, khác độ tuổi hoặc khác điều kiện chiếu sáng có thể có calibration kém hơn dù accuracy tổng thể vẫn cao.

2.2.3 Calibration trong lượng tử hóa và Knowledge Distillation

Trong lượng tử hóa sau huấn luyện, calibration còn có nghĩa là ước lượng dải giá trị của trọng số và activation để xác định scale và zero-point. Quá trình này thường được thực hiện bằng cách chạy một tập dữ liệu đại diện qua mô hình và ghi nhận thống kê min-max hoặc histogram [18]. Nếu tập calibration không đại diện, scale có thể quá hẹp hoặc quá rộng, làm tăng clipping error hoặc rounding error. Với QAT, các observer tiếp tục cập nhật thống kê trong quá trình train; tuy nhiên, nếu observer thay đổi quá lâu, student phải đồng thời thích nghi với nhiều lượng tử hóa và dải lượng tử biến động. Vì vậy, việc đóng băng observer sau giai đoạn warm-up giúp bài toán tối ưu ổn định hơn.

Knowledge Distillation không chỉ hỗ trợ nén mô hình mà còn có thể cải thiện calibration. Teacher thường cung cấp soft targets, tức phân phối xác suất trên toàn bộ lớp thay vì chỉ nhãn one-hot. Phân phối này chứa *dark knowledge* về quan hệ giữa các lớp, bao gồm cả mức độ không chắc chắn của teacher [12, 7]. Khi student, đặc biệt là student lượng tử hóa như Q6, học theo soft targets, nó không chỉ học quyết định cuối cùng mà còn học mức confidence hợp lý hơn. Hebbalaguppe và cộng sự gọi quá trình này là calibration transfer và cho thấy tri thức hiệu chuẩn có thể được truyền từ teacher sang student thông qua distillation [11].



Hình 2.7: Động lực của calibration transfer qua Knowledge Distillation [11].

Hình 2.7 minh họa ba tình huống truyền tri thức từ teacher sang student. Ở trường hợp bên trái, teacher chưa được hiệu chuẩn tạo ra soft targets quá tự tin, làm student dễ học theo các confidence sai lệch. Ở trường hợp giữa, các phương pháp làm mềm nhãn tính như label smoothing có thể giảm overconfidence nhưng cũng có nguy cơ làm mờ quan hệ phân biệt giữa các lớp. Ở trường hợp bên phải, teacher đã được hiệu chuẩn động cung cấp phân phối xác suất phù hợp hơn cho từng mẫu; nhờ đó student học được không chỉ nhãn dự đoán mà còn cả mức độ không chắc chắn của teacher. Đây là cơ sở để calibration transfer qua Knowledge Distillation cải thiện độ tin cậy của student sau lượng tử hóa.

Đối với khóa luận này, calibration có hai vai trò bổ sung cho nhau. Thứ nhất, calibration của lượng tử hóa giúp xác định miền giá trị ổn định cho trọng số và activation. Thứ hai, calibration xác suất giúp đánh giá student có quá tự tin sau lượng tử hóa hay không. Kết hợp QAT với Knowledge Distillation vì vậy có thể vừa giảm sai số biểu diễn low-bit, vừa giúp student duy trì confidence hợp lý hơn khi triển khai trong các điều kiện xác minh khuôn mặt thực tế.

2.3 Nhận dạng khuôn mặt và không gian embedding

2.3.1 Tổng quan bài toán nhận dạng khuôn mặt

Nhận dạng khuôn mặt là bài toán xác định hoặc xác minh danh tính của một người dựa trên ảnh khuôn mặt. Trong thực tế, bài toán này thường được chia thành hai thiết lập chính: *face identification* và *face verification*. Identification là bài toán 1-N, trong đó hệ thống cần tìm danh tính phù hợp nhất trong một tập danh tính đã biết. Verification là bài toán 1-1, trong đó hệ thống nhận hai ảnh và quyết định chúng có thuộc cùng một danh tính hay không. Khóa luận này tập trung vào thiết lập verification vì đây là giao thức phổ biến để đánh giá khả năng tổng quát hóa của embedding trên các danh tính chưa thấy.


Các phương pháp học sâu đã tạo ra bước chuyển lớn trong nhận dạng khuôn mặt. DeepFace cho thấy mạng nơ-ron sâu kết hợp căn chỉnh khuôn mặt có thể thu hẹp khoảng cách với hiệu năng con người trong xác minh khuôn mặt [31]. FaceNet tiếp tục định hình cách tiếp cận hiện đại bằng cách học trực tiếp một không gian embedding, trong đó khoảng cách giữa hai vector phản ánh mức độ giống nhau của hai khuôn mặt [28]. Sau đó, các phương pháp dựa trên biên góc như SphereFace, CosFace và ArcFace cải thiện khả năng phân tách danh tính bằng cách tối ưu trực tiếp hình học góc của embedding [19, 33, 5].

Một hệ thống nhận dạng khuôn mặt hiện đại thường gồm ba bước như trong Hình 2.8. Đầu tiên, khuôn mặt được phát hiện và căn chỉnh để giảm biến thiên do vị trí, tỷ lệ hoặc tư thế. Tiếp theo, backbone CNN như ResNet hoặc iResNet trích xuất vector embedding có số chiều cố định. Cuối cùng, hệ thống so sánh các embedding bằng cosine similarity hoặc khoảng cách Euclidean để đưa ra quyết định. Các bộ dữ liệu như CASIA-WebFace và VGGFace2 thường được dùng để huấn luyện hoặc đánh giá khả năng học biểu diễn trong điều kiện đa dạng về tư thế, tuổi tác và điều kiện thu nhận ảnh [35, 4].

2.3.2 Không gian embedding trong nhận dạng khuôn mặt

Trong nhận dạng khuôn mặt, mô hình không chỉ cần phân loại đúng các danh tính trong tập huấn luyện mà còn phải tổng quát hóa sang các danh tính chưa từng thấy. Vì vậy, đầu ra quan trọng nhất của iResNet là không gian embedding. Các ảnh cùng danh tính cần được ánh xạ gần nhau, trong khi ảnh khác danh tính cần nằm xa nhau theo độ đo cosine. Các hàm mất mát như ArcFace và CosFace thêm margin vào không gian góc nhằm tăng khoảng cách giữa các lớp và giảm khoảng cách trong cùng lớp [5, 33].

Lượng tử hóa thấp bit có thể làm nhiễu embedding theo hai cách. Thứ nhất, sai số làm tròn trong trọng số và activation có thể làm thay đổi hướng của vector embedding. Thứ hai, các thay đổi nhỏ trong cosine similarity có thể ảnh hưởng lớn đến quyết định



Hình 2.8: Pipeline tổng quát của một hệ thống nhận dạng khuôn mặt hiện đại.

ở vùng gần ngưỡng. Vì vậy, với nhận dạng khuôn mặt, accuracy trung bình chưa đủ để đánh giá mô hình; cần xem xét thêm các chỉ số ở ngưỡng xác minh nghiêm ngặt.

Hai nhóm chỉ số được sử dụng trong khóa luận là accuracy và TAR@FAR, được đánh giá trên các giao thức xác minh phổ biến như LFW, CFP-FP, AgeDB-30, CALFW và CPLFW [14, 30, 22, 39, 38]. Accuracy đo tỷ lệ cặp ảnh được phân loại đúng trong giao thức xác minh. FAR (False Acceptance Rate) là tỷ lệ chấp nhận nhầm cặp khác danh tính:

$$\text{FAR} = \frac{\text{số cặp khác danh tính bị chấp nhận}}{\text{tổng số cặp khác danh tính}}. \quad (2.19)$$

TAR (True Acceptance Rate) là tỷ lệ chấp nhận đúng cặp cùng danh tính:

$$\text{TAR} = \frac{\text{số cặp cùng danh tính được chấp nhận}}{\text{tổng số cặp cùng danh tính}}. \quad (2.20)$$

TAR@FAR=10⁻⁴ nghĩa là hệ thống chọn ngưỡng sao cho tỷ lệ chấp nhận nhầm chỉ khoảng 0.01%, sau đó đo tỷ lệ chấp nhận đúng tại ngưỡng đó. Chỉ số này đặc biệt quan trọng trong các ứng dụng bảo mật, nơi một mô hình có accuracy cao nhưng TAR thấp tại FAR nhỏ vẫn chưa đủ tin cậy để triển khai thực tế.

2.4 Kiến trúc mạng nơ-ron tích chập ResNet và iResNet

Để giải quyết các khó khăn khi huấn luyện mạng nơ-ron sâu, He và cộng sự đề xuất kiến trúc Residual Network (ResNet), trong đó các lớp không học trực tiếp ánh xạ mục tiêu mà học phần dư của ánh xạ đó [10]. ResNet là nền tảng cho nhiều backbone nhận dạng khuôn mặt hiện đại, bao gồm iResNet-18 được sử dụng trong khóa luận này. Trong bối cảnh nén mô hình và lượng tử hóa, việc hiểu cơ chế residual learning là cần thiết vì shortcut connection giúp gradient lan truyền ổn định hơn, đồng thời giúp mô hình nhỏ hoặc low-bit duy trì chất lượng embedding tốt hơn.

2.4.1 Vấn đề thoái hóa trong mạng sâu

Trước ResNet, các nghiên cứu về huấn luyện mạng sâu đã chỉ ra rằng tín hiệu gradient có thể bị suy giảm hoặc khuếch đại khi lan truyền qua nhiều lớp, khiến các lớp gần đầu vào học rất chậm hoặc không ổn định [1, 6]. Vấn đề này thường được gọi là vanishing/exploding gradients. Các nguyên nhân quan trọng bao gồm hàm kích hoạt bị bão hòa, khởi tạo trọng số không phù hợp và sự mất cân bằng phương sai của activation hoặc gradient giữa các lớp.

Tuy nhiên, He và cộng sự nhấn mạnh thêm một hiện tượng khác là *degradation problem*: khi tăng số lớp, accuracy trên tập huấn luyện có thể bão hòa rồi suy giảm, trong khi training error lại tăng lên [10]. Đây không phải là overfitting, vì overfitting thường làm training error thấp nhưng test error cao. Ngược lại, degradation cho thấy mạng sâu hơn khó tối ưu hơn ngay cả trên tập huấn luyện. Kết quả thực nghiệm trên CIFAR-10 trong bài ResNet cho thấy plain network 56 lớp có training error cao hơn plain network 20 lớp, dù về lý thuyết mạng sâu hơn có năng lực biểu diễn lớn hơn.


2.4.2 Cơ chế học thặng dư

Ý tưởng cốt lõi của ResNet là thay vì để một chuỗi lớp học trực tiếp ánh xạ mong muốn $H(x)$, mạng học hàm phần dư $F(x) = H(x) - x$. Khi đó ánh xạ gốc được viết lại thành:

$$H(x) = F(x) + x. \quad (2.21)$$

Trong đó x là đầu vào của khối, $F(x)$ là biến đổi phi tuyến được học bởi các lớp convolution, Batch Normalization và ReLU, còn $+x$ là shortcut connection cộng trực tiếp đầu vào vào đầu ra của nhánh chính.

Hình 2.9 minh họa trực quan cách ResNet bổ sung đường truyền tắt vào một khối convolution thông thường. Thay vì chỉ truyền tín hiệu qua chuỗi lớp phi tuyến, đầu vào x được giữ lại và cộng với đầu ra của nhánh học phần dư $F(x)$. Nhờ đó, nếu các lớp mới



Hình 2.9: Sơ đồ khối residual cơ bản trong ResNet

chưa học được biến đổi hữu ích, mạng có thể đưa $F(x)$ tiến gần về 0 để đầu ra xấp xỉ ánh xạ đồng nhất $H(x) \approx x$. Cơ chế này làm cho việc tối ưu mạng sâu trở nên ổn định hơn so với plain network, đồng thời giảm nguy cơ degradation khi tăng số lớp [10].

Về lan truyền ngược, với $H(x) = F(x) + x$, gradient của hàm mất mát $\mathcal{L}$ theo đầu vào x có dạng:

$$\frac{\partial \mathcal{L}}{\partial x} = \frac{\partial \mathcal{L}}{\partial H} \left(1 + \frac{\partial F}{\partial x} \right). \quad (2.22)$$


Số hạng 1 tạo ra một đường truyền gradient trực tiếp qua shortcut. Ngay cả khi $\partial F / \partial x$ nhỏ, gradient vẫn có thể truyền về các lớp trước thông qua nhánh đồng nhất, giúp quá trình huấn luyện ổn định hơn.

2.4.3 Kiến trúc ResNet-18 và iResNet-18

ResNet-18 là biến thể nhẹ trong họ ResNet, gồm các khối residual cơ bản với hai lớp convolution 3×3 . Kiến trúc này thường được tổ chức thành bốn stage, mỗi stage tăng số kênh đặc trưng và giảm kích thước không gian của feature map. Nhờ số tầng vừa phải, ResNet-18 phù hợp với các bài toán cân bằng giữa độ chính xác và chi phí tính toán.

iResNet là biến thể ResNet được điều chỉnh cho nhận dạng khuôn mặt. Thay vì tối ưu trực tiếp cho phân loại ảnh tổng quát, iResNet được dùng như một backbone trích xuất embedding khuôn mặt. Đầu ra của mạng thường là vector embedding 512 chiều, sau đó được chuẩn hóa L2 để phục vụ so sánh bằng cosine similarity. So với ResNet gốc, các biến thể iResNet trong nhận dạng khuôn mặt thường chú trọng tạo không gian embedding ổn định, có khả năng phân tách danh tính tốt và phù hợp với các hàm mất mát biên góc như ArcFace hoặc CosFace [5, 33].

Để làm rõ sự khác biệt giữa ResNet-18 gốc và biến thể iResNet-18 được sử dụng trong khóa luận, Bảng 2.3 tổng hợp các điểm khác nhau về mục tiêu thiết kế, đầu ra cuối, cơ chế chuẩn hóa embedding và khả năng tích hợp các toán tử hỗ trợ QAT. Bảng này cho thấy iResNet-18 không chỉ là ResNet-18 dùng lại cho bài toán khuôn mặt, mà đã được điều chỉnh để tạo embedding 512 chiều ổn định hơn cho xác minh danh tính và phù hợp hơn với quá trình lượng tử hóa Q6.



Hình 2.10: Sơ đồ kiến trúc ResNet-18

Bảng 2.3: So sánh ResNet-18 truyền thống và iResNet-18 trong bài toán nhận dạng khuôn mặt Q6.

Tiêu chí	ResNet-18 truyền thống	iResNet-18 trong khóa luận
Bài toán	Phân loại ảnh tổng quát, thường trên ImageNet.	Xác minh/nhận dạng khuôn mặt thông qua embedding.
Đầu ra cuối	Logits hoặc xác suất 1.000 lớp.	Embedding 512 chiều, chuẩn hóa L2 để so sánh cosine.
Tầng cuối	Fully-connected layer cho phân loại ImageNet.	Tầng embedding/projection; trong QAT có thể thay bằng QuantLinear .
Mục tiêu thiết kế	Học đặc trưng ngữ nghĩa cho nhiều lớp ảnh tổng quát.	Tạo không gian embedding phân biệt: cùng danh tính gần, khác danh tính xa.
Hàm mất mát	Cross-entropy với nhãn phân loại.	ArcFace/CosFace hoặc căn chỉnh embedding với teacher.
Chuẩn hóa	Không bắt buộc chuẩn hóa đầu ra cuối.	Chuẩn hóa L2 là bước quan trọng trước khi tính cosine similarity.
Hỗ trợ QAT	Bản gốc không tích hợp sẵn fake-quantization.	Có thể gắn QuantAct cho activation và QuantLinear cho tầng cuối.
Vai trò trong khóa luận	Cơ sở để giải thích residual learning và truyền gradient.	Backbone chính để đánh giá Q6, observer freezing và β -MSE.

Hình 2.10 minh họa cấu trúc tổng quát của ResNet-18. Sau lớp convolution ban đầu, mạng đi qua bốn nhóm khối residual; ở mỗi nhóm, số kênh đặc trưng thường tăng dần trong khi kích thước không gian của feature map giảm xuống. Cách tổ chức này giúp mạng học được đặc trưng từ mức thấp đến mức cao: các lớp đầu tập trung vào cạnh, kết cấu và chi tiết cục bộ, còn các lớp sâu hơn biểu diễn thông tin ngữ nghĩa giàu hơn. Trong bài toán nhận dạng khuôn mặt, iResNet-18 kế thừa tinh thần của ResNet-18 nhưng thay phần phân loại cuối bằng đầu ra embedding. Mỗi ảnh khuôn mặt được ánh xạ thành vector e , sau đó các embedding đã chuẩn hóa được so sánh bằng cosine similarity:

$$\text{sim}(e_1, e_2) = \frac{e_1^\top e_2}{\|e_1\|_2 \|e_2\|_2}. \quad (2.23)$$

Nếu similarity vượt qua một ngưỡng τ , hệ thống kết luận hai ảnh thuộc cùng một danh tính; ngược lại, hệ thống từ chối cặp ảnh. Do đó, chất lượng embedding quyết định trực tiếp khả năng xác minh.

Chương 3

Phương pháp đề xuất

3.1 Quy trình tổng thể

Chương này trình bày phương pháp đề xuất cho bài toán lượng tử hóa 6-bit trong nhận dạng khuôn mặt. Mục tiêu của phương pháp là thiết kế một quy trình huấn luyện student Q6 có khả năng bảo toàn cấu trúc phân biệt của không gian embedding full-precision, đồng thời vẫn phù hợp với yêu cầu triển khai trên thiết bị tài nguyên hạn chế. Phương pháp gồm bốn thành phần chính: khung lượng tử hóa Q6, mục tiêu căn chỉnh embedding có trọng số β -MSE, lịch huấn luyện ba pha và chiến lược dữ liệu tinh lọc.

Tổng quan phương pháp được minh họa trong Hình 3.1. Mô hình teacher f_t được giữ ở full-precision và đóng vai trò mốc tham chiếu ổn định. Mô hình student f_s có kiến trúc tương ứng với teacher, nhưng trọng số và kích hoạt được đưa vào cơ chế lượng tử hóa 6-bit trong quá trình huấn luyện. Với các kiến trúc nhận dạng khuôn mặt sinh embedding 512 chiều, quy trình này có thể được áp dụng như một lớp huấn luyện bổ sung mà không cần thay đổi bản chất kiến trúc mạng.


Với ảnh đầu vào x , teacher và student lần lượt sinh embedding:

$$\mathbf{t} = f_t(x), \quad \mathbf{s} = f_s(x). \quad (3.1)$$

Hai embedding được chuẩn hóa về độ dài đơn vị:

$$\tilde{\mathbf{t}} = \frac{\mathbf{t}}{\|\mathbf{t}\|_2}, \quad \tilde{\mathbf{s}} = \frac{\mathbf{s}}{\|\mathbf{s}\|_2}. \quad (3.2)$$

Việc chuẩn hóa L2 giúp hàm căn chỉnh tập trung vào hướng của vector đặc trưng, phù hợp với cơ chế so sánh cosine similarity trong nhận dạng khuôn mặt và các hàm mất mát biên góc như ArcFace hoặc CosFace [5, 33]. Do đó, student không chỉ học để dự đoán nhãn đúng, mà còn được ràng buộc để bảo toàn hình học embedding của teacher.



Hình 3.1: Tổng quan phương pháp đề xuất

3.2 Khung lượng tử hóa Q6

Trong bài toán nhận dạng khuôn mặt, lượng tử hóa thấp bit khó hơn nhiều so với các bài toán phân loại thông thường, vì hiệu năng xác minh phụ thuộc vào các quan hệ hình học rất nhỏ trong không gian embedding. Một sai lệch nhỏ ở embedding cuối có thể làm giảm độ compact trong cùng danh tính hoặc làm yếu khoảng cách giữa các danh tính khác nhau. Vì vậy, student Q6 không được tối ưu độc lập, mà luôn được dẫn dắt bởi teacher full-precision.

Với một tensor thực x , phép lượng tử hóa b -bit được mô tả bởi:

$$Q_b(x) = \text{clip} \left(\text{round} \left(\frac{x}{s} \right) + z, q_{\min}, q_{\max} \right), \quad (3.3)$$

trong đó b là bit-width, s là quantization scale, z là zero-point, còn $q_{\min}$ và $q_{\max}$ xác định miền số nguyên ứng với b . Giá trị giải lượng tử được tính như sau:

$$\hat{x} = s(Q_b(x) - z). \quad (3.4)$$

Trong cấu hình Q6, $b = 6$, phép ánh xạ này được áp dụng cho student để trọng số tích chập và kích hoạt trung gian đều bị ràng buộc vào biểu diễn 6-bit. Cách làm này giúp giảm chi phí bộ nhớ và tính toán, nhưng cũng tạo ra độ lệch giữa phân phối đặc trưng low-bit và full-precision [17, 18]. Độ lệch này là nguyên nhân chính khiến cần thêm cơ chế căn chỉnh embedding mạnh trong quá trình huấn luyện.

3.3 Điều phối gradient bằng β -MSE

Mục tiêu căn chỉnh chính của phương pháp là β -weighted Mean Squared Error, gọi tắt là β -MSE. Với batch gồm N ảnh, hàm mất mát điều phối gradient được định nghĩa:

$$\mathcal{L}_{GC} = \beta \cdot \frac{1}{N} \sum_{i=1}^N \|\tilde{\mathbf{s}}_i - \tilde{\mathbf{t}}_i\|_2^2, \quad (3.5)$$

trong đó β là hệ số khuếch đại tín hiệu căn chỉnh. Khi kết hợp với huấn luyện có nhãn, mục tiêu tổng quát có thể viết dưới dạng:

$$\mathcal{L} = \alpha \mathcal{L}_{CE} + \mathcal{L}_{GC} = \alpha \mathcal{L}_{CE} + \beta \mathcal{L}_{MSE}. \quad (3.6)$$

Ở đây, $\mathcal{L}_{CE}$ giữ năng lực phân loại theo danh tính, còn $\mathcal{L}_{GC}$ giữ student đi theo cấu trúc biểu diễn của teacher.

Điểm quan trọng của β -MSE là nó không chỉ yêu cầu student tạo ra embedding cuối giống teacher, mà còn liên tục điều chỉnh hướng cập nhật tham số trong suốt quá trình tối ưu. Trong môi trường low-bit, student chịu sai số rời rạc hóa ở nhiều tầng; các sai số nhỏ này có thể tích lũy và làm phân phối đặc trưng trôi khỏi mốc full-precision. Đồng thời, do embedding đã được chuẩn hóa L2, giá trị MSE thô giữa hai vector thường có biên độ nhỏ, khiến gradient sửa sai không đủ mạnh nếu không được khuếch đại.

Vì vậy, hệ số β được đưa vào để tăng sức hút của student về đa tạp embedding của teacher. Khi β đủ lớn, sai khác đặc trưng bị phạt mạnh hơn, buộc student sửa các lệch hướng do lượng tử hóa gây ra. Trong khóa luận, β được xem là một siêu tham số điều phối gradient chứ không phải hằng số cố định. Giá trị của β cần được chọn theo mức độ nhiễu lượng tử hóa, kiến trúc student, batch size và độ khó của dữ liệu. Nếu β quá nhỏ, student dễ đi lệch khỏi teacher; nếu quá lớn, student có thể bị ép sao chép teacher quá cứng và giảm khả năng thích nghi với dữ liệu huấn luyện.


Do đó, tên gọi “điều phối gradient” nhấn mạnh rằng mục tiêu của phương pháp không chỉ là giảm sai khác embedding tại điểm hội tụ. Quan trọng hơn, β -MSE cung cấp một tín hiệu tối ưu mạnh và ổn định hơn, giúp student Q6 đi theo quỹ đạo cập nhật gần với teacher full-precision. Đây là yếu tố đặc biệt cần thiết trong nhận dạng khuôn mặt low-bit, nơi méo embedding là nguyên nhân trực tiếp làm giảm hiệu năng xác minh.

3.4 Chiến lược huấn luyện ba pha

Bên cạnh hàm căn chỉnh embedding, phương pháp đề xuất sử dụng lịch huấn luyện ba pha để ổn định tối ưu. Động lực của thiết kế này là mạng lượng tử hóa rất nhạy với nhiễu hiệu chuẩn và nhiễu tối ưu, đặc biệt ở giai đoạn đầu khi dải kích hoạt chưa ổn định. Lịch huấn luyện đi từ warm-up, sang cố định dải lượng tử, rồi tinh chỉnh với learning rate

giảm dần.

Luồng dữ liệu của lịch huấn luyện ba pha được minh họa trong Hình 3.2. Cùng một ảnh đầu vào được đưa đồng thời qua teacher full-precision và student Q6. Teacher chỉ thực hiện lan truyền thuận để sinh embedding tham chiếu ổn định, trong khi student đi qua các observer và quantizer để mô phỏng điều kiện suy luận 6-bit. Embedding của student sau đó được so sánh với embedding của teacher thông qua hàm mất mát β -MSE; gradient chỉ cập nhật student, còn teacher được giữ cố định.



Hình 3.2: Sơ đồ luồng dữ liệu trong chiến lược huấn luyện ba pha.

Trong sơ đồ này, observer là các module đóng vai trò “bộ quan sát”. Chúng theo dõi và thu thập thống kê của tensor đi qua mạng, chẳng hạn giá trị nhỏ nhất, lớn nhất hoặc các thống kê tương đương, để ước lượng dải động phù hợp cho lượng tử hóa. Dải động là miền giá trị số thực $[FP_{\min}, FP_{\max}]$ của trọng số hoặc activation trước khi bị ánh xạ sang miền số nguyên low-bit. Trong Pha 1, student cần quan sát đủ dữ liệu để xác định dải động này; nếu dải quá hẹp, giá trị ngoài biên bị cắt gây clipping error, còn nếu dải quá rộng thì độ phân giải lượng tử bị giảm.

Quantizer sử dụng cơ chế lượng tử hóa mô phỏng, hay fake quantization, để đưa sai số lượng tử hóa vào ngay trong lan truyền thuận. Cụ thể, tensor thực được lượng tử hóa sang lưới 6-bit rồi giải lượng tử trở lại dạng số thực, nhờ đó phép tính vẫn tương thích với lan truyền ngược và cập nhật gradient. Cơ chế này giúp student học cách thích nghi với nhiễu 6-bit trong quá trình huấn luyện, thay vì chỉ bị lượng tử hóa sau khi đã hội tụ ở full-precision. Khi observer đã bị đóng băng từ Pha 2, scale và zero-point trở nên ổn định hơn; đến Pha 3, learning rate giảm dần giúp mô hình tinh chỉnh quanh nghiệm low-bit, tức bộ tham số đã hội tụ trong điều kiện ràng buộc lượng tử hóa thấp bit.

3.4.1 Pha 1: Warm-up

Ở pha warm-up, student được thích nghi dần với chế độ lượng tử hóa. Các module lượng tử hóa tiếp tục thu thập thông kê kích hoạt để ước lượng dải động phù hợp. Đồng thời, learning rate bắt đầu từ giá trị nhỏ và tăng dần đến mức cơ sở. Cách khởi động này làm giảm nguy cơ dao động tối ưu đột ngột, giúp student tiếp xúc với sai số lượng tử hóa theo cách có kiểm soát hơn.

3.4.2 Pha 2: Freeze observers

Sau khi dải kích hoạt đã được ước lượng đủ ổn định, các observer được đóng băng. Mục đích của bước này là giữ cố định dải lượng tử, để student được tối ưu trong một cấu hình số học nhất quán. Nếu observer tiếp tục thay đổi liên tục, scale và zero-point dao động có thể tạo thêm nhiễu cho quá trình học. Khi dải động đã cố định, student có thể tập trung hơn vào nhiệm vụ căn chỉnh embedding với teacher.

3.4.3 Pha 3: Fine-tuning

Ở pha cuối, mô hình được tinh chỉnh dưới cấu hình Q6 cố định. Learning rate giảm dần để student thực hiện các cập nhật nhỏ và chính xác quanh nghiệm low-bit tốt. Giai đoạn này giúp cải thiện chất lượng hội tụ và giảm sai khác còn lại giữa embedding teacher và student. Vì quá trình tối ưu được thực hiện trên dữ liệu thực được tinh lọc thay vì dữ liệu tổng hợp quy mô lớn, mô hình cuối phù hợp hơn với mục tiêu học hiệu quả dữ liệu.

Lịch learning rate tổng quát theo epoch e có thể biểu diễn như sau:

$$\eta_e = \begin{cases} \eta_{\min}^{\text{warm}} + \frac{e}{4} (\eta_0 - \eta_{\min}^{\text{warm}}), & \text{warm-up,} \\ \eta_0, & \text{main training,} \\ \eta_{\min}^{\text{cos}} + (\eta_0 - \eta_{\min}^{\text{cos}}) \frac{1 + \cos(\pi(e - 25)/5)}{2}, & \text{fine-tuning,} \end{cases} \quad (3.7)$$

trong đó η_0 là learning rate cơ sở, $\eta_{\min}^{\text{warm}}$ là learning rate nhỏ nhất ở warm-up, và $\eta_{\min}^{\text{cos}}$ là learning rate nhỏ nhất ở pha tinh chỉnh. Công thức này phản ánh nguyên tắc huấn luyện của phương pháp: ổn định dải động trước, sau đó tối ưu mạnh, cuối cùng giảm bước học để hội tụ mượt hơn.

Dựa trên hiện thực huấn luyện iResNet-18 Q6, thời điểm đóng băng observer và cập nhật learning rate được mô tả trong Thuật toán 3.1. Cấu hình thực nghiệm dùng 30 epoch: 5 epoch đầu là warm-up, các epoch từ 5 đến 24 giữ learning rate cơ sở, và từ epoch 25 trở đi chuyển sang cosine fine-tuning. Observer được đóng băng ngay khi bắt đầu epoch thứ 5 theo chỉ số đếm từ 0, tức sau khi hoàn tất 5 epoch warm-up đầu tiên.

Trong đó, hàm `freeze_observer` có hai tác dụng. Thứ nhất, các module có phương

Thuật toán 3.1: Quy trình huấn luyện ba pha cho student Q6

```

1 Input: teacher FP32  $f_t$ , student Q6  $f_s$ , tập huấn luyện  $\mathcal{D}$ , số epoch  $E = 30$ , learning rate
  cơ sở  $\eta_0 = 10^{-3}$ , hệ số  $\beta$ ;
2 Output: student Q6 đã tinh chỉnh;
3 Khởi tạo teacher ở chế độ eval và cố định toàn bộ tham số teacher;
4 Lượng tử hóa student với  $b_w = b_a = 6$ , sau đó khởi tạo optimizer SGD và scheduler ba
  pha;
5 for epoch  $e = 0, 1, \dots, E - 1$  do
6   if  $e < 5$  then
7     Đặt pha warm-up và cho observer tiếp tục thu thập thống kê activation;
8   else if  $e \geq 5$  then
9     Gọi freeze_observer( $f_s$ ) để cố định observer, scale và quantizer nếu có;
10  end
11  for mỗi mini-batch  $x \in \mathcal{D}$  do
12    Tính  $\tilde{\mathbf{t}} = \text{normalize}(f_t(x))$  trong no_grad;
13    Tính  $\tilde{\mathbf{s}} = \text{normalize}(f_s(x))$ ;
14    Tính  $\mathcal{L} = \beta \text{MSE}(\tilde{\mathbf{s}}, \tilde{\mathbf{t}})$ , lan truyền ngược và clip gradient với ngưỡng 1.0;
15    Cập nhật tham số student bằng optimizer;
16  end
17  Cập nhật learning rate: tăng tuyến tính nếu  $e < 5$ , giữ  $\eta_0$  nếu  $5 \leq e < 25$ , cosine decay
  nếu  $e \geq 25$ ;
18  Lưu checkpoint và đánh giá xác minh trên tập validation;
19 end
20 Chọn checkpoint student Q6 có kết quả xác minh tốt nhất.

```


thức `disable_observer` sẽ ngừng cập nhật thống kê activation, làm cho dải lượng tử ổn định hơn. Thứ hai, các tham số hoặc biến liên quan đến observer, quantizer và scale không tiếp tục thay đổi trong quá trình tối ưu. Nhờ vậy, từ Pha 2 trở đi student không phải thích nghi với một hệ quy chiếu lượng tử hóa liên tục dao động, còn Pha 3 chỉ tập trung giảm sai khác embedding bằng các bước học nhỏ theo lịch cosine.

3.5 Chiến lược dữ liệu tinh lọc

Khác với các hướng phụ thuộc vào dữ liệu tổng hợp quy mô lớn như QuantFace [2], phương pháp đề xuất đi theo hướng dữ liệu tinh lọc. Thay vì mở rộng số lượng ảnh bằng mọi giá, khóa luận sử dụng khoảng 53.500 ảnh thực từ CASIA-WebFace, VGGFace2 và IMDB-WIKI. Triết lý ở đây là “quality over quantity”: tập dữ liệu nhỏ hơn nhưng chứa các biến thiên có giá trị cao cho nhận dạng khuôn mặt low-bit.

Tập dữ liệu gồm ba phần. Phần chính là CASIA-1k với khoảng 48.458 ảnh, cung cấp nền tảng danh tính và phân phối khuôn mặt thực cho quá trình huấn luyện. Hình 3.3 minh họa trực quan ba thành phần dữ liệu này, còn Bảng 3.1 trình bày thống kê định lượng của từng thành phần dữ liệu. Hai biến thể Pose và Age được bổ sung có chủ đích từ VGGFace2 và IMDB-WIKI nhằm minh chứng cho chiến lược “quality over quantity”.

Các mẫu trong Hình 3.3 nhấn mạnh hai đặc điểm của dữ liệu tinh lọc. Thứ nhất, dữ liệu đã được xử lý qua phát hiện và căn chỉnh khuôn mặt theo chuẩn sử dụng trong các pipeline nhận dạng hiện đại, giúp giảm nhiễu do vị trí và tỉ lệ khuôn mặt không nhất



Hình 3.3: Các mẫu ảnh tiêu biểu trong tập dữ liệu tinh lọc.

quán. Thứ hai, dữ liệu thể hiện tính đa dạng trong sự thống nhất: cùng một danh tính có thể xuất hiện với góc nhìn hoặc độ tuổi rất khác nhau, nhưng mô hình vẫn phải học embedding ổn định để nhận diện đó là cùng một người. Đây là lý do tập dữ liệu không cần mở rộng quá lớn về số lượng, mà tập trung vào các biến thiên có giá trị cao đối với nhận dạng khuôn mặt Q6.

Bảng 3.1: Thống kê định lượng các thành phần dữ liệu tinh lọc.

Thành phần dữ liệu	Nguồn gốc	Số danh tính	Số lượng ảnh	Mục tiêu tối ưu
CASIA-1k	CASIA-WebFace	1.000	48.458	Cung cấp phân phối khuôn mặt thực
Tập Pose	VGGFace2	200	2.000	Tăng độ bền vững với góc nghiêng, hỗ trợ CFP-FP và CPLFW
Tập Age	IMDB-WIKI	300	3.000	Tăng độ bền vững với độ tuổi, hỗ trợ AgeDB-30 và CALFW
Tổng cộng	—	1.500	53.458	Hội tụ nhanh và bảo toàn embedding

Phần thứ hai là tập pose từ VGGFace2, gồm 200 danh tính, mỗi danh tính 10 ảnh, tổng cộng 2.000 ảnh. Phần này bổ sung các góc nhìn khó, đặc biệt liên quan đến các benchmark có biến thiên pose như CFP-FP và CPLFW. Phần thứ ba là tập age từ IMDB-WIKI, gồm 300 danh tính, mỗi danh tính 10 ảnh, tổng cộng 3.000 ảnh, nhằm tăng độ đa dạng tuổi và hỗ trợ đánh giá trên các giao thức như AgeDB-30 và CALFW.

Chiến lược dữ liệu này có vai trò hỗ trợ trực tiếp cho β -MSE. Các ảnh pose lớn hoặc

chênh lệch tuổi thường làm embedding thay đổi mạnh hơn ảnh chính diện thông thường. Khi student bị lượng tử hóa Q6, những biến thiên này dễ bị méo hơn do sai số rời rạc hóa. Bằng cách chủ động đưa các mẫu pose và age chất lượng cao vào huấn luyện, student nhận được tín hiệu gradient giàu thông tin hơn ở đúng các vùng khó của không gian embedding. So với việc dùng hàng trăm nghìn ảnh tổng hợp, dữ liệu thực tình lọc có ba lợi ích. Thứ nhất, nó giảm nguy cơ domain gap giữa ảnh tổng hợp và ảnh kiểm thử thực tế. Thứ hai, số lượng ảnh nhỏ giúp giảm chi phí huấn luyện và hỗ trợ hội tụ nhanh hơn. Thứ ba, dữ liệu được chọn có mục đích giúp student không chỉ sao chép teacher, mà còn học thêm các đặc trưng sinh trắc bền vững từ các biến thiên pose và age. Về mặt phương pháp, cách chọn dữ liệu này giúp giảm phụ thuộc vào quy trình sinh ảnh tổng hợp, đồng thời tạo điều kiện để student học trực tiếp từ các phân bố khuôn mặt thực có ý nghĩa đối với bài toán xác minh.

Tóm lại, phương pháp đề xuất là một khung thống nhất gồm Q6 quantization, teacher-guided embedding alignment bằng β -MSE, huấn luyện ba pha và dữ liệu thực tình lọc. Sự kết hợp này hướng tới mục tiêu thực tế: tạo mô hình nhận dạng khuôn mặt low-bit đủ nhẹ cho thiết bị biên, nhưng vẫn bảo toàn được cấu trúc phân biệt của embedding full-precision.

Chương 4

Thực nghiệm, phân tích và thảo luận

4.1 Thiết lập thí nghiệm

Các thí nghiệm được thiết kế nhằm đánh giá hiệu quả của phương pháp lượng tử hóa Q6 trong nhận dạng khuôn mặt. Trọng tâm đánh giá gồm ba nội dung: mức suy giảm của lượng tử hóa trực tiếp sau huấn luyện (PTQ), vai trò của hệ số β trong phục hồi embedding và khả năng tổng quát hóa của mô hình trên các benchmark có biến thiên pose và age.

Môi trường cài đặt sử dụng Python và PyTorch, kết hợp các thư viện xử lý dữ liệu và đánh giá như NumPy, OpenCV/Pillow và scikit-learn. Quá trình huấn luyện được thực hiện trên máy có GPU hỗ trợ CUDA để tăng tốc lan truyền thuận và lan truyền ngược. Các mô hình được huấn luyện với SGD, momentum 0.9, weight decay 5×10^{-4} , batch size 128 và lịch huấn luyện tối đa 60 epochs. Learning rate được điều khiển theo cosine annealing ở giai đoạn cuối để giảm dần biên độ cập nhật và giúp mô hình hội tụ ổn định hơn.

Quy trình huấn luyện tuân theo chiến lược ba pha đã trình bày ở Chương 3. Pha đầu là warm-up, trong đó learning rate tăng dần và observer thu thập thống kê kích hoạt. Pha thứ hai là main training, trong đó observer được đóng băng để cố định dải lượng tử. Pha cuối là fine-tuning với cosine annealing nhằm tinh chỉnh student Q6 dưới cấu hình lượng tử cố định.

Các benchmark được sử dụng gồm LFW, CFP-FP, AgeDB-30, CALFW và CPLFW [14, 30, 22, 39, 38]. LFW đại diện cho điều kiện nhận dạng tổng quát; CFP-FP nhấn mạnh biến thiên frontal–profile; AgeDB-30 tập trung vào biến thiên tuổi; CALFW và CPLFW lần lượt kiểm tra thêm độ khó về age và pose. Hai chỉ số chính là verification accuracy và TAR@FAR= 10^{-4} . Accuracy phản ánh độ đúng trung bình, trong khi TAR@FAR= 10^{-4} phản ánh khả năng chấp nhận đúng tại ngưỡng sai chấp nhận rất thấp.

4.2 Kết quả baseline: FP32 và Q6 PTQ

Baseline đầu tiên là mô hình FP32, đóng vai trò mốc tham chiếu. Baseline thứ hai là Q6 PTQ, trong đó mô hình đã huấn luyện được lượng tử hóa trực tiếp sang 6-bit mà không có fine-tuning bằng teacher. Bảng 4.1 tổng hợp kết quả baseline cho ba kiến trúc iResNet-18, iResNet-50 và MobileFaceNet. Kết quả cho thấy PTQ vẫn giữ accuracy khá cao trên một số benchmark, nhưng $\text{TAR@FAR}=10^{-4}$ có thể giảm rất mạnh.

Bảng 4.1: Baseline FP32 và Q6 PTQ: accuracy và $\text{TAR@FAR}=10^{-4}$.

Kiến trúc	Chỉ số	Mô hình	LFW	CFP-FP	AgeDB-30	CALFW	CPLFW
iResNet-18	Accuracy	FP32	99.617	93.671	96.687	95.533	89.183
	Accuracy	Q6 PTQ	99.500	92.671	96.633	95.283	87.733
	TAR	FP32	99.133	77.686	84.967	85.000	50.733
	TAR	Q6 PTQ	99.033	71.429	84.000	83.300	56.933
iResNet-50	Accuracy	FP32	99.800	95.957	97.983	96.083	92.217
	Accuracy	Q6 PTQ	99.683	91.557	96.083	95.133	87.017
	TAR	FP32	99.600	88.914	92.900	90.500	53.533
	TAR	Q6 PTQ	98.500	67.343	76.400	82.833	0.100
MobileFaceNet	Accuracy	FP32	99.433	91.529	95.567	95.150	87.800
	Accuracy	Q6 PTQ	98.150	83.400	89.267	91.067	77.017
	TAR	FP32	98.167	65.857	74.500	84.700	9.600
	TAR	Q6 PTQ	91.600	25.286	24.600	49.600	0.067

Hiện tượng quan trọng là accuracy có thể giảm ít trong khi TAR giảm mạnh. Với iResNet-18, accuracy sau PTQ gần như được giữ nguyên trên AgeDB-30, từ 96.687% xuống 96.633%, nhưng TAR vẫn giảm từ 84.967% xuống 84.000%. Trên CFP-FP, iResNet-18 giảm accuracy 1.000 điểm phần trăm, từ 93.671% xuống 92.671%, trong khi TAR giảm mạnh hơn, từ 77.686% xuống 71.429%. Điều này cho thấy ngay cả kiến trúc tương đối ổn định như iResNet-18 vẫn chịu tác động rõ ở ngưỡng FAR thấp.

Với iResNet-50, hiện tượng này rõ hơn trên AgeDB-30: accuracy giảm từ 97.983% xuống 96.083%, tức chỉ giảm 1.900 điểm phần trăm, nhưng TAR giảm từ 92.900% xuống 76.400%, tức giảm 16.500 điểm phần trăm. Trên CPLFW, iResNet-50 PTQ gần như mất khả năng hoạt động ở ngưỡng FAR nghiêm ngặt khi TAR chỉ còn 0.100%. MobileFaceNet cũng cho thấy độ nhạy cao với lượng tử hóa: trên CFP-FP, accuracy giảm từ 91.529% xuống 83.400%, còn TAR giảm từ 65.857% xuống 25.286%.

Điều này cho thấy lượng tử hóa không chỉ làm giảm khả năng phân loại trung bình, mà còn làm méo hình học embedding. Ở ngưỡng FAR thấp, chỉ một sai lệch nhỏ trong cosine similarity cũng có thể làm nhiều cặp đúng bị loại bỏ. Vì vậy, đánh giá mô hình nhận dạng khuôn mặt Q6 cần dựa trên cả accuracy và TAR@FAR thấp, thay vì chỉ quan sát accuracy.

4.3 Tối ưu hóa siêu tham số β

Hệ số β điều khiển cường độ của thành phần MSE trong hàm mất mát tổng:

$$\mathcal{L} = \alpha\mathcal{L}_{CE} + \beta\mathcal{L}_{MSE}. \quad (4.1)$$

Trong bài toán nhận dạng khuôn mặt Q6, $\mathcal{L}_{CE}$ giúp student duy trì khả năng phân loại trên tập huấn luyện, còn $\mathcal{L}_{MSE}$ trực tiếp kéo embedding của student về gần embedding teacher. Vì các benchmark xác minh khuôn mặt dựa trên khoảng cách hoặc cosine similarity giữa embedding, việc tối ưu β có ảnh hưởng trực tiếp đến TAR@FAR thấp.

Bảng 4.2 trình bày accuracy khi thay đổi β trên ba kiến trúc. Nhìn chung, accuracy không biến động quá mạnh giữa các giá trị β . Điều này cho thấy chỉ số accuracy tương đối bảo hòa và chưa đủ nhạy để phản ánh đầy đủ chất lượng embedding sau lượng tử hóa.

Bảng 4.2: So sánh accuracy (%) khi thay đổi hệ số β .

Model	β	LFW	CFP-FP	AgeDB-30	CALFW	CPLFW
iResNet-18	1	99.517	92.486	96.717	95.417	88.917
iResNet-18	200	99.467	93.214	96.450	95.483	88.983
iResNet-18	300	99.550	92.857	96.783	95.500	88.400
iResNet-50	1	99.733	94.257	97.333	95.833	90.433
iResNet-50	200	99.767	95.043	97.683	95.817	91.767
iResNet-50	300	99.750	95.488	97.567	95.767	91.550
MobileFaceNet	1	98.700	88.257	92.567	93.367	84.733
MobileFaceNet	200	99.183	90.443	93.883	94.033	86.450
MobileFaceNet	300	99.317	90.514	93.867	93.650	86.600

Bảng 4.3 cho thấy sự khác biệt rõ hơn ở TAR@FAR= 10^{-4} . Với iResNet-18, $\beta = 300$ cho kết quả tốt nhất trên CFP-FP, đạt 76.543%, trong khi $\beta = 1$ tốt hơn trên CALFW và CPLFW. Với iResNet-50, $\beta = 200$ phục hồi AgeDB-30 tốt nhất, đạt 92.700%, còn $\beta = 300$ tốt hơn trên CFP-FP, đạt 85.657%. Với MobileFaceNet, $\beta = 200$ tốt nhất trên CFP-FP và AgeDB-30, nhưng $\beta = 300$ tốt hơn trên LFW và CPLFW.

Từ hai bảng trên có thể rút ra ba nhận xét. Thứ nhất, accuracy khá ổn định khi thay đổi β , nhưng TAR@FAR= 10^{-4} thay đổi mạnh hơn nhiều. Ví dụ, với iResNet-50, accuracy trên AgeDB-30 chỉ tăng từ 97.333% ở $\beta = 1$ lên 97.683% ở $\beta = 200$, trong khi TAR tăng từ 74.233% lên 92.700%. Điều này cho thấy β -MSE tác động chủ yếu vào chất lượng hình học của embedding, chứ không chỉ cải thiện phân loại.

Thứ hai, MSE quan trọng hơn CE trong phục hồi TAR vì CE không trực tiếp tối ưu khoảng cách giữa các embedding. Khi β quá nhỏ, gradient từ CE có thể vẫn giúp mô hình đạt accuracy cao, nhưng embedding student vẫn bị lệch khỏi teacher do nhiễu lượng tử hóa. Khi tăng β , tín hiệu căn chỉnh embedding mạnh hơn, giúp student phục hồi tốt

Bảng 4.3: So sánh TAR@FAR= 10^{-4} sau 30 epochs với lịch 5–20–5 khi thay đổi β .

Model	β	LFW	CFP-FP	AgeDB-30	CALFW	CPLFW
iResNet-18	1	99.067	71.086	77.300	87.267	53.100
iResNet-18	200	99.033	73.029	87.900	84.933	25.700
iResNet-18	300	99.133	76.543	85.633	85.533	25.067
iResNet-50	1	98.933	81.343	74.233	88.367	36.000
iResNet-50	200	99.333	81.943	92.700	89.333	37.000
iResNet-50	300	99.333	85.657	91.867	88.333	31.000
MobileFaceNet	1	94.100	40.629	31.267	72.533	2.000
MobileFaceNet	200	94.400	62.914	44.400	73.200	1.400
MobileFaceNet	300	95.900	56.857	40.100	72.300	4.033

hơn ở các giao thức khó như CFP-FP và AgeDB-30.

Thứ ba, không tồn tại một giá trị β tối ưu tuyệt đối cho mọi kiến trúc và benchmark. Các kiến trúc có dung lượng khác nhau phản ứng khác nhau với β . iResNet-50 hưởng lợi rõ từ $\beta = 200$ trên AgeDB-30, MobileFaceNet cũng cần $\beta = 200$ để cải thiện CFP-FP và AgeDB-30, trong khi iResNet-18 có một số benchmark đạt tốt hơn với $\beta = 1$. Vì vậy, β nên được xem là siêu tham số điều phối gradient cần chọn theo mục tiêu đánh giá: nếu ưu tiên pose thì quan sát CFP-FP/CPLFW, nếu ưu tiên age thì quan sát AgeDB-30/CALFW.

4.4 Đánh giá tính robustness

Robustness được đánh giá trên toàn bộ năm benchmark: LFW, CFP-FP, AgeDB-30, CALFW và CPLFW. Các tập này bao phủ nhiều điều kiện khác nhau, từ nhận dạng tổng quát đến biến thiên pose và age. Để đánh giá đầy đủ tác động của lượng tử hóa và chiến lược huấn luyện, Bảng 4.4 so sánh bốn cấu hình: FP32, Q6 PTQ, Q6 wo-3p và Q6 w-3p.

Trên LFW, các mô hình Q6 sau huấn luyện nhìn chung vẫn giữ TAR cao. iResNet-18 w-3p đạt 99.233%, thậm chí cao hơn FP32 99.133%; iResNet-50 w-3p đạt 99.333%, chỉ thấp hơn nhẹ so với FP32 99.600%. Điều này cho thấy phương pháp không làm mất năng lực nhận dạng trong điều kiện tổng quát.

Trên CFP-FP, benchmark nhấn mạnh biến thiên pose frontal–profile, huấn luyện Q6 có tác dụng rõ rệt so với PTQ. iResNet-50 tăng từ 67.343% ở PTQ lên 85.657% ở w-3p, còn MobileFaceNet tăng từ 25.286% lên 62.914%. Điều này cho thấy dữ liệu pose và β -MSE giúp student học embedding ổn định hơn trước thay đổi góc nhìn.

Trên AgeDB-30 và CALFW, các biến thiên tuổi làm lộ rõ khác biệt giữa PTQ và huấn luyện có căn chỉnh embedding. iResNet-50 trên AgeDB-30 tăng từ 76.400% ở PTQ lên 92.700% ở w-3p, gần sát FP32 92.900%. iResNet-18 w-3p cũng vượt FP32 trên AgeDB-30 và CALFW, lần lượt đạt 87.900% và 87.267%.

Trên CPLFW, kết quả cho thấy ảnh hưởng của kiến trúc và lịch huấn luyện không


Bảng 4.4: Đánh giá robustness trên năm benchmark bằng TAR@FAR=10⁻⁴.

Kiến trúc	Mô hình	LFW	CFP-FP	AgeDB-30	CALFW	CPLFW
iResNet-18	FP32	99.133	77.686	84.967	85.000	50.733
	Q6 PTQ	99.033	71.429	84.000	83.300	56.933
	Q6 wo-3p	99.067	73.429	76.033	83.900	49.567
	Q6 w-3p	99.233	76.543	87.900	87.267	53.100
iResNet-50	FP32	99.600	88.914	92.900	90.500	53.533
	Q6 PTQ	98.500	67.343	76.400	82.833	0.100
	Q6 wo-3p	99.433	81.514	88.300	90.433	56.233
	Q6 w-3p	99.333	85.657	92.700	89.333	37.000
MobileFaceNet	FP32	98.167	65.857	74.500	84.700	9.600
	Q6 PTQ	91.600	25.286	24.600	49.600	0.067
	Q6 wo-3p	94.767	31.800	31.800	76.000	15.133
	Q6 w-3p	95.900	62.914	44.400	73.200	4.033

hoàn toàn giống nhau. iResNet-50 wo-3p đạt 56.233%, cao hơn FP32 53.533% và cao hơn w-3p 37.000%. Điều này gợi ý rằng với kiến trúc có dung lượng lớn, mô hình có thể khai thác biến thiên pose từ dữ liệu tinh lọc tốt hơn khi không bị ràng buộc quá chặt bởi lịch ba pha. Ngược lại, với iResNet-18, w-3p vẫn cho kết quả tốt hơn wo-3p trên hầu hết benchmark.

Tóm lại, đánh giá trên cả năm tập cho thấy robustness của phương pháp phụ thuộc vào cả kiến trúc, benchmark và cách dùng lịch ba pha. Q6 w-3p thường ổn định hơn trên LFW, CFP-FP và AgeDB-30, trong khi Q6 wo-3p có thể có lợi trong một số trường hợp pose cực đoan như iResNet-50 trên CPLFW. Điều này cho thấy cần đánh giá đồng thời nhiều benchmark thay vì chỉ dựa vào một tập kiểm thử duy nhất. Để giải thích rõ hơn kết quả trên AgeDB-30, khóa luận tham khảo thêm các bản đồ Grad-CAM của các cặp ảnh được trích xuất từ báo cáo thí nghiệm nội bộ năm 2025, như minh họa trong Hình 4.1. Grad-CAM tạo bản đồ chú ý bằng cách sử dụng gradient của lớp mục tiêu đi vào tầng tích chập cuối, từ đó làm nổi bật các vùng ảnh có đóng góp lớn nhất cho quyết định của mô hình [29]. Vì vậy, Grad-CAM phù hợp để kiểm tra liệu mô hình nhận dạng khuôn mặt có tập trung vào các vùng sinh trắc quan trọng như mắt, mũi, miệng và đường viền khuôn mặt hay bị phân tán sang nền, tóc hoặc vùng nhiễu không liên quan.

Từ Hình 4.1, quan sát định tính trên các cặp ảnh AgeDB-30 cho thấy mô hình FP32 thường tạo vùng kích hoạt rộng hơn, đôi khi lan sang tóc, nền hoặc vùng cổ áo. Ngược lại, student Q6 sau huấn luyện ba pha có xu hướng tập trung gọn hơn vào vùng trung tâm khuôn mặt và các đặc trưng ổn định qua tuổi tác. Hiện tượng này có thể được lý giải bởi hai yếu tố. Thứ nhất, lượng tử hóa 6-bit đóng vai trò như một ràng buộc làm giảm độ tự do của mô hình, khiến student ít dựa vào các tín hiệu phụ có biên độ nhỏ hoặc không ổn định. Thứ hai, mục tiêu β -MSE buộc embedding của student bám sát teacher, trong



Hình 4.1: So sánh bản đồ Grad-CAM giữa mô hình FP32 và student Q6 trên các cặp ảnh AgeDB-30.

khi dữ liệu Age được tinh lọc làm tăng tần suất xuất hiện của biến thiên tuổi trong quá trình tối ưu.

Nhờ sự kết hợp này, Q6 không chỉ phục hồi sai số do lượng tử hóa mà còn học được cơ chế chú ý tập trung hơn vào các vùng có giá trị nhận dạng bền vững. Điều này giúp giải thích vì sao trên AgeDB-30, mô hình Q6 w-3p có thể đạt Recovery Rate xấp xỉ 102% so với FP32: hiệu năng không chỉ đến từ việc giữ lại thông tin của teacher, mà còn từ tác dụng regularization của lượng tử hóa và dữ liệu tinh lọc, làm giảm phụ thuộc vào các đặc trưng nhiễu khi khuôn mặt thay đổi theo tuổi.

4.5 Hiệu quả của việc đóng băng observer

Observer có nhiệm vụ thu thập thống kê activation để xác định scale và zero-point cho lượng tử hóa. Trong Q6, mỗi tensor chỉ có 64 mức biểu diễn, vì vậy lựa chọn dải lượng tử có ảnh hưởng rất lớn đến sai số làm tròn. Nếu observer tiếp tục cập nhật trong toàn bộ quá trình huấn luyện, scale và zero-point sẽ thay đổi liên tục. Khi đó, student không chỉ phải tối ưu trọng số, mà còn phải thích nghi với một hệ quy chiếu số học luôn dao động.

Việc đóng băng observer sau giai đoạn warm-up giúp tách hai nhiệm vụ. Giai đoạn đầu dùng để ước lượng dải kích hoạt đủ đại diện; giai đoạn sau cố định dải này để tối ưu embedding. Khi dải lượng tử đã ổn định, gradient từ β -MSE trở nên nhất quán hơn vì cùng một sai lệch embedding không còn bị diễn giải dưới các scale khác nhau qua từng

epoch. Điều này đặc biệt quan trọng với nhận dạng khuôn mặt, nơi sai lệch nhỏ trong embedding có thể làm thay đổi quyết định xác minh ở ngưỡng FAR thấp.

Có thể xem observer freezing như một cơ chế giảm nhiễu tối ưu. Nếu không đóng băng observer, quá trình học đồng thời phải giải quyết hai nguồn nhiễu: nhiễu lượng tử hóa do 6-bit và nhiễu dải động do thống kê activation thay đổi. Khi observer được cố định, nguồn nhiễu thứ hai giảm đi, giúp student tập trung hơn vào việc bám sát teacher full-precision.

4.6 So sánh với các nghiên cứu liên quan

QuantFace là một hướng tiếp cận tiêu biểu cho nhận dạng khuôn mặt lượng tử hóa thấp bit, trong đó dữ liệu tổng hợp quy mô lớn được dùng để hỗ trợ phục hồi hiệu năng [2]. Điểm mạnh của hướng này là tạo được nhiều ảnh bổ sung cho quá trình huấn luyện. Tuy nhiên, nó cũng làm tăng chi phí sinh dữ liệu, lưu trữ và huấn luyện, đồng thời có thể phát sinh khoảng cách giữa ảnh tổng hợp và ảnh thật.

Phương pháp trong khóa luận đi theo hướng khác: giảm phụ thuộc vào quy mô dữ liệu và tăng chất lượng tín hiệu tối ưu. Thay vì dùng khoảng 500k ảnh tổng hợp, tập dữ liệu tinh lọc gồm khoảng 53.5k ảnh thực được chọn để bổ sung đúng các biến thiên quan trọng như pose và age. Đồng thời, β -MSE trực tiếp căn chỉnh embedding student với teacher, giúp quá trình phục hồi tập trung vào hình học biểu diễn thay vì chỉ học phân loại.

Về thời gian huấn luyện, nếu so sánh theo số mẫu xử lý đến khi hội tụ hữu ích, dữ liệu tinh lọc có lợi thế rõ rệt. Với 53.5k ảnh và khoảng 30 epoch hiệu dụng, số ảnh đi qua mô hình xấp xỉ 1.605 triệu. Với 500k ảnh và 60 epoch, con số tương ứng là 30 triệu. Tỷ lệ này xấp xỉ 19 lần, cho thấy việc chọn dữ liệu có mục tiêu có thể tiết kiệm đáng kể chi phí huấn luyện so với mở rộng dữ liệu tổng hợp.

Về độ chính xác, Bảng 4.5 cho thấy phương pháp đề xuất đạt kết quả cạnh tranh với QuantFace dù chỉ dùng khoảng 0.053M ảnh huấn luyện. Trên iResNet-18, mô hình đề xuất đạt 99.633% trên LFW và 96.817% trên AgeDB-30 ở thiết lập không dùng lịch ba pha, cao hơn cả teacher FP32 ở hai benchmark này. Với MobileFaceNet, lịch ba pha giúp cải thiện rõ rệt trên toàn bộ năm benchmark, trong đó CFP-FP tăng từ 87.314% lên 90.514% và CPLFW tăng từ 83.967% lên 86.600%. Điều này cho thấy chiến lược căn chỉnh embedding kết hợp dữ liệu tinh lọc đặc biệt có ích với kiến trúc nhẹ, vốn nhạy hơn với nhiễu lượng tử hóa.

Ở chỉ số nghiêm ngặt hơn TAR@FAR=10⁻⁴, Bảng 4.6 nhấn mạnh rõ hơn lợi ích của huấn luyện Q6 có định hướng. So với PTQ, phương pháp đề xuất phục hồi mạnh trên các benchmark khó: iResNet-50 tăng từ 67.343% lên 85.657% trên CFP-FP và từ 76.400% lên 92.700% trên AgeDB-30 khi dùng lịch ba pha; MobileFaceNet tăng từ 25.286% lên 62.914% trên CFP-FP. Tuy nhiên, kết quả trên CPLFW cũng cho thấy lịch ba pha không

Bảng 4.5: So sánh Accuracy (Q6) giữa các kiến trúc và benchmark.

Kiến trúc	Loại mô hình	Ảnh huấn luyện	LFW	CFP-FP	AgeDB-30	CALFW	CPLFW
Accuracy (Q6)							
iResNet-18	FP32 [2]	5.8M	99.617	93.671	96.687	95.533	89.183
	RealQuantFace [2]	5.8M	99.520	93.230	96.550	95.580	88.370
	SynQuantFace [2]	0.5M	99.550	93.340	96.620	95.320	89.050
	PTQ	–	99.500	92.671	96.633	95.283	87.733
	Ours (wo-3p)	0.053M	99.633	92.729	96.817	95.600	88.800
	Ours (w-3p)	0.053M	99.617 ($\beta=50$)	92.857 ($\beta=300$)	96.450 ($\beta=200$)	95.417 ($\beta=1$)	88.917 ($\beta=1$)
iResNet-50	FP32 [2]	5.8M	99.800	95.957	97.983	96.083	92.217
	RealQuantFace [2]	5.8M	99.700	95.000	97.170	95.870	90.170
	SynQuantFace [2]	0.5M	99.680	95.170	97.430	95.700	90.380
	PTQ	–	99.683	91.557	96.083	95.133	87.017
	Ours (wo-3p)	0.053M	99.686	93.786	97.417	95.817	90.217
	Ours (w-3p)	0.053M	99.750 ($\beta=300$)	92.857 ($\beta=300$)	97.683 ($\beta=200$)	95.817 ($\beta=200$)	91.767 ($\beta=200$)
MobileFaceNet	FP32 [2]	5.8M	99.433	91.529	95.567	95.150	87.800
	RealQuantFace [2]	5.8M	98.870	87.690	93.030	93.300	84.570
	SynQuantFace [2]	0.5M	99.080	87.640	91.770	93.480	84.850
	PTQ	–	98.150	83.400	89.267	91.067	77.017
	Ours (wo-3p)	0.053M	98.883	87.314	92.450	93.317	83.967
	Ours (w-3p)	0.053M	99.317 ($\beta=300$)	90.514 ($\beta=200$)	93.867 ($\beta=200$)	93.650 ($\beta=200$)	86.600 ($\beta=300$)

phải lúc nào cũng tối ưu cho mọi kiến trúc, chẳng hạn iResNet-50 đạt TAR cao nhất ở thiết lập không dùng ba pha. Nhìn chung, các kết quả này gợi ý rằng trong nhận dạng khuôn mặt low-bit, yếu tố quyết định không chỉ là số lượng ảnh, mà còn là cách điều phối gradient, lựa chọn lịch huấn luyện và chất lượng biến thiên trong dữ liệu huấn luyện.

Bảng 4.6: So sánh TAR@FAR=10⁻⁴ (Q6) giữa các kiến trúc và benchmark.

Kiến trúc	Loại mô hình	Ảnh huấn luyện	LFW	CFP-FP	AgeDB-30	CALFW	CPLFW
TAR@FAR=10 ⁻⁴							
iResNet-18	FP32 [2]	5.8M	99.133	77.686	84.967	85.000	50.733
	PTQ	–	99.033	71.429	84.000	83.300	56.933
	Ours (wo-3p)	0.053M	99.067	73.429	76.033	83.900	49.567
	Ours (w-3p)	0.053M	99.233 ($\beta=50$)	76.543 ($\beta=300$)	87.900 ($\beta=200$)	87.267 ($\beta=1$)	53.100 ($\beta=1$)
iResNet-50	FP32 [2]	5.8M	99.600	88.914	92.900	90.500	53.533
	PTQ	–	98.500	67.343	76.400	82.833	0.100
	Ours (wo-3p)	0.053M	99.433	81.514	88.300	90.433	56.233
	Ours (w-3p)	0.053M	99.333 ($\beta=300$)	85.657 ($\beta=300$)	92.700 ($\beta=200$)	89.333 ($\beta=200$)	37.000 ($\beta=200$)
MobileFaceNet	FP32 [2]	5.8M	98.167	65.857	74.500	84.700	9.600
	PTQ	–	91.600	25.286	24.600	49.600	0.067
	Ours (wo-3p)	0.053M	94.767	31.800	31.800	76.000	15.133
	Ours (w-3p)	0.053M	95.900 ($\beta=300$)	62.914 ($\beta=200$)	44.400 ($\beta=200$)	73.200 ($\beta=200$)	4.033 ($\beta=300$)

4.6.1 Phân tích hiện tượng iResNet-50 wo-3p vượt teacher trên CPLFW

Một điểm đáng chú ý trong Bảng 4.6 là iResNet-50 ở thiết lập Q6 không dùng lịch ba pha (wo-3p) đạt TAR@FAR=10⁻⁴ là 56.233% trên CPLFW, cao hơn teacher FP32 với 53.533%. Kết quả này không nên được hiểu đơn giản là lượng tử hóa luôn làm student tốt hơn teacher, mà phản ánh tương tác giữa chất lượng teacher, đặc thù dữ liệu pose cực đoan và mức độ ràng buộc của distillation trong quá trình huấn luyện.

CPLFW là benchmark nhấn mạnh biến thiên pose, trong đó nhiều cặp ảnh có khác biệt lớn về góc nhìn. Ở điều kiện này, teacher FP32 không còn là mốc tham chiếu hoàn hảo: TAR 53.533% cho thấy embedding của teacher vẫn gặp khó khăn khi khuôn mặt bị xoay mạnh hoặc xuất hiện các cấu hình frontal–profile phức tạp. Nếu student bị ép bám quá chặt vào teacher thông qua lịch huấn luyện ba pha và tín hiệu distillation mạnh, student có thể kế thừa cả những giới hạn của teacher trên miền pose cực đoan. Điều này

phù hợp với kết quả iResNet-50 w-3p chỉ đạt 37.000% trên CPLFW, thấp hơn đáng kể so với wo-3p.

Thiết lập wo-3p có thể được xem như một trạng thái “tháo bỏ kìm kẹp” khỏi tín hiệu teacher. Khi không bị ràng buộc quá chặt bởi quỹ đạo distillation và lịch đồng bộ theo ba pha, student iResNet-50 vẫn có đủ dung lượng biểu diễn để tự điều chỉnh embedding dựa trên dữ liệu thực tế đã được tinh lọc. Tập dữ liệu này chứa các mẫu pose có mục tiêu, nên student có cơ hội học trực tiếp những biến thiên góc nhìn mà teacher xử lý chưa tối ưu. Nói cách khác, với kiến trúc có dung lượng lớn như iResNet-50, việc giảm mức phụ thuộc vào teacher trong một số giai đoạn có thể tạo thêm không gian tối ưu để student khai thác tín hiệu từ dữ liệu thật.

Hiện tượng này cũng cho thấy distillation không phải lúc nào cũng nên được áp dụng như một ràng buộc tuyệt đối. Khi teacher mạnh trên miền đánh giá, chẳng hạn AgeDB-30 hoặc CFP-FP, việc bám sát teacher giúp phục hồi embedding hiệu quả. Ngược lại, khi teacher có hiệu suất thấp ở một miền khó như CPLFW, ràng buộc distillation quá chặt có thể làm student bị giới hạn bởi chính sai lệch của teacher. Vì vậy, kết quả iResNet-50 wo-3p vượt teacher trên CPLFW gợi ý rằng chiến lược huấn luyện Q6 nên linh hoạt theo benchmark: với pose cực đoan, cần cân bằng giữa học từ teacher và học trực tiếp từ dữ liệu tinh lọc, thay vì mặc định tăng cường distillation ở mọi trường hợp.

4.6.2 Recovery rate và mức độ bảo toàn tri thức

Bên cạnh TAR tuyệt đối, khóa luận sử dụng recovery rate để đo trực tiếp mức độ student Q6 giữ lại năng lực của teacher FP32 sau lượng tử hóa. Thước đo này được định nghĩa theo tỉ lệ giữa TAR của student và TAR của teacher trên cùng benchmark:

$$RecoveryRate = \frac{TAR_{Student_Q6}}{TAR_{Teacher_FP32}}. \quad (4.2)$$

Giá trị xấp xỉ 1 cho thấy student bảo toàn gần như đầy đủ hiệu năng của teacher; giá trị nhỏ hơn 1 phản ánh phần hiệu năng bị mất do lượng tử hóa; còn giá trị lớn hơn 1 cho thấy student vượt teacher trong điều kiện đánh giá tương ứng.

Bảng 4.7: Recovery rate khi dùng CASIA-1k và CASIA-1k kết hợp dữ liệu tinh lọc.

Dữ liệu huấn luyện	LFW	CFP-FP	AgeDB-30	CALFW	CPLFW
CASIA-1k	0.999	0.949	1.007	1.000	0.210
CASIA-1k + dữ liệu tinh lọc	1.000	0.985	1.008	1.030	1.050

Cách diễn giải theo recovery rate đặc biệt hữu ích vì mục tiêu chính của bài toán Q6 không chỉ là đạt một con số TAR cao, mà là giảm bit trong khi giữ lại tối đa tri thức của mô hình full-precision. Theo kết quả trong paper tham chiếu, khi chỉ dùng CASIA-1k, recovery rate trên CPLFW chỉ đạt 0.21, cho thấy dữ liệu nền chưa đủ để phục hồi robustness trước pose cực đoan. Khi bổ sung dữ liệu tinh lọc theo pose và age, recovery

rate tăng lên 1.05 trên CPLFW, 1.03 trên CALFW và 1.008 trên AgeDB-30. Điều này cho thấy dữ liệu thực tế được chọn có mục tiêu không chỉ bù lại suy giảm do lượng tử hóa, mà còn giúp student học các biến thiên khó mà teacher hoặc tập dữ liệu gốc chưa xử lý tối ưu.

Trên AgeDB-30, recovery rate xấp xỉ 102% là một ví dụ tiêu biểu: student Q6 không chỉ phục hồi hiệu năng bị mất sau lượng tử hóa, mà còn vượt nhẹ teacher nhờ tác dụng kết hợp của β -MSE, lịch huấn luyện ổn định và dữ liệu age-oriented. Vì vậy, recovery rate đóng vai trò như một chỉ số trung tâm để chứng minh rằng phương pháp không đơn thuần nén mô hình, mà còn bảo toàn và trong một số trường hợp cải thiện hình học embedding dưới các biến thiên thực tế.

4.6.3 Relative gap và so sánh công bằng giữa các giao thức

Khi so sánh với các nghiên cứu liên quan, một vấn đề quan trọng là các công trình không phải lúc nào cũng dùng cùng giao thức đánh giá và cùng tập kiểm thử. Chẳng hạn, QuantFace báo cáo nhiều kết quả trên IJB-B/IJB-C và dùng khoảng 500k ảnh tổng hợp cho quá trình phục hồi lượng tử hóa, trong khi khóa luận này tập trung vào các benchmark LFW, CFP-FP, AgeDB-30, CALFW và CPLFW với khoảng 53.5k ảnh thực tế được tinh lọc. Do IJB-B/IJB-C và các bộ LFW/CFP/AgeDB khác nhau về phân bố dữ liệu, độ khó, cách tạo cặp hoặc template và quy trình tính TAR, việc so sánh trực tiếp các giá trị TAR tuyệt đối giữa hai hướng là không hoàn toàn khách quan.

Vì lý do đó, khóa luận sử dụng sai số tương đối so với teacher (Relative Gap) như một thước đo chuẩn hóa công bằng hơn. Thay vì chỉ hỏi student đạt TAR tuyệt đối bao nhiêu trên một benchmark cụ thể, Relative Gap đo khoảng cách giữa student Q6 và chính teacher FP32 trong cùng điều kiện đánh giá:

$$Gap = TAR_{Teacher} - TAR_{Student_Q6}. \quad (4.3)$$

Gap dương càng nhỏ cho thấy student càng gần teacher; gap âm cho thấy student vượt teacher trên benchmark đó. Cách nhìn này phù hợp với mục tiêu của bài toán low-bit face recognition, vì trọng tâm không chỉ là đạt điểm cao tuyệt đối, mà là bảo toàn nhiều nhất năng lực của mô hình full-precision sau khi giảm bit.

Bảng 4.8: Relative Gap theo $TAR@FAR=10^{-4}$ trên các benchmark.

Kiến trúc	Relative Gap ($TAR@FAR=10^{-4}$)						
	IJB-C	IJB-B	LFW	CFP-FP	AgeDB-30	CALFW	CPLFW
iResNet-18 (real) [2]	0.530	0.560	–	–	–	–	–
iResNet-50 (real) [2]	4.000	4.120	–	–	–	–	–
MobileFaceNet (real) [2]	7.750	8.010	–	–	–	–	–
iResNet-18 (w-3p)	–	–	-0.100	1.143	-2.933	-2.267	-2.367
iResNet-50 (wo-3p)	–	–	0.167	7.400	4.600	0.067	-2.700
MobileFaceNet (w-3p)	–	–	2.267	2.943	30.100	11.500	5.567

Cách tiếp cận này làm cho so sánh giữa các nghiên cứu ít phụ thuộc hơn vào lựa chọn benchmark. Một mô hình được đánh giá trên IJB-B/IJB-C và một mô hình được đánh giá trên LFW/CFP/AgeDB có thể có TAR tuyệt đối rất khác nhau do độ khó của tập kiểm thử, nhưng cả hai đều có thể được phân tích theo khoảng cách tương đối đến teacher tương ứng của chúng. Theo paper tham chiếu, QuantFace có relative gap khoảng 0.53–8.01 điểm phần trăm trên IJB-B/IJB-C tùy kiến trúc, trong khi phương pháp của khóa luận đạt nhiều gap âm trên các benchmark đang xét, chẳng hạn iResNet-18 w-3p đạt -2.933 trên AgeDB-30 và -2.367 trên CPLFW, còn iResNet-50 wo-3p đạt -2.700 trên CPLFW.

Các gap âm này không có nghĩa là mọi student đều tốt hơn teacher trong mọi điều kiện, mà cho thấy student có thể vượt mốc teacher ở một số miền cụ thể khi dữ liệu tinh lọc cung cấp tín hiệu pose hoặc age giàu thông tin hơn. Nói cách khác, Relative Gap là thước đo phù hợp để trả lời câu hỏi cốt lõi của khóa luận: sau khi chuyển từ FP32 sang Q6, student còn cách teacher bao xa, hoặc trong trường hợp tốt nhất, đã vượt teacher ở miền nào? Khi được chuẩn hóa theo teacher, kết quả trên các bộ kiểm thử khác nhau có thể được diễn giải nhất quán hơn, đồng thời tránh kết luận thiếu công bằng từ việc so sánh trực tiếp TAR tuyệt đối giữa IJB-C, LFW, CFP-FP, AgeDB-30 hoặc các giao thức đánh giá khác.

4.7 Phân tích tốc độ hội tụ

Bên cạnh độ chính xác, tốc độ hội tụ là một tiêu chí quan trọng vì mục tiêu của khóa luận là xây dựng quy trình huấn luyện Q6 thực dụng cho môi trường tài nguyên hạn chế. Phương pháp đề xuất sử dụng tập dữ liệu tinh lọc khoảng 53.500 ảnh thực, thay vì phụ thuộc vào dữ liệu quy mô rất lớn. Tuy nhiên, để so sánh công bằng với các hướng huấn luyện khác, cần chuẩn hóa theo cùng batch size thay vì chỉ so sánh số epoch.

Trong thiết lập thực nghiệm, batch size gốc là 128. Với khoảng 53.500 ảnh, một epoch cần xấp xỉ:

$$\frac{53500}{128} \approx 418 \quad (4.4)$$

iterations. Với lịch fine-tuning 30 epochs, tổng số iteration ở batch size 128 là:

$$418 \times 30 \approx 12540. \quad (4.5)$$

Khi chuẩn hóa về batch size 512, số iteration tương đương giảm theo tỉ lệ $128/512 = 1/4$:

$$12540 \times \frac{128}{512} = 3135. \quad (4.6)$$

Trong khi đó, hướng huấn luyện quy mô lớn như QuantFace cần khoảng 180.000 iterations ở batch size 512 [2]. Do đó, hệ số tăng tốc hội tụ khi so sánh trên cùng batch

size được tính như sau:

$$Speedup = \frac{180000}{3135} \approx 57.4. \quad (4.7)$$

Nói cách khác, sau khi chuẩn hóa cùng batch size, phương pháp đề xuất cần ít iteration hơn khoảng 57.4 lần để hoàn tất quá trình fine-tuning Q6.

Bảng 4.9: So sánh chi phí hội tụ sau khi chuẩn hóa về batch size 512.

Thiết lập	Batch size gốc	Iteration gốc	Iteration chuẩn hóa
Dữ liệu tinh lọc 53.5k ảnh	128	12.540	3.135
Huấn luyện quy mô lớn	512	180.000	180.000

Kết quả này cho thấy lợi ích của phương pháp không chỉ đến từ việc dùng ít ảnh hơn, mà còn đến từ cách điều phối tối ưu. Tập dữ liệu tinh lọc cung cấp các biến thiên quan trọng như pose và age, trong khi β -MSE giúp student bám sát quỹ đạo embedding của teacher. Kết hợp với lịch huấn luyện ba pha, đặc biệt là đóng băng observer sau giai đoạn warm-up, quá trình tối ưu trở nên ổn định hơn và không cần số lượng iteration quá lớn.

Về mặt trực quan, đường cong hội tụ có thể được hiểu như sau. Ở giai đoạn đầu, warm-up giúp giảm dao động do dải kích hoạt chưa ổn định. Sau khi observer được đóng băng, scale và zero-point không còn thay đổi liên tục, nên loss embedding giảm đều hơn. Ở giai đoạn fine-tuning, cosine annealing làm learning rate nhỏ dần, giúp student tinh chỉnh quanh nghiệm Q6 tốt mà không phá vỡ dải lượng tử đã học. Nhờ đó, mô hình có thể đạt vùng hội tụ hữu ích với chi phí iteration thấp hơn đáng kể so với hướng mở rộng dữ liệu quy mô lớn.

4.8 Phân tích về lưu trữ thực tế

Trong quá trình huấn luyện QAT, fake quantization được dùng để mô phỏng ảnh hưởng của lượng tử hóa trong forward pass, trong khi tham số thường vẫn được lưu ở dạng số thực để phục vụ backpropagation. Vì vậy, kích thước checkpoint trong quá trình huấn luyện chưa phản ánh đầy đủ dung lượng có thể tiết kiệm khi triển khai inference thực sự.

Khi triển khai, nếu trọng số FP32 được chuyển sang biểu diễn 6-bit, dung lượng lý thuyết cho phần trọng số giảm theo tỉ lệ:

$$\frac{32}{6} \approx 5.33. \quad (4.8)$$

Nói cách khác, riêng phần lưu trữ trọng số có tiềm năng giảm khoảng 5.33 lần so với FP32. Ví dụ, nếu một mô hình cần 100 MB để lưu trọng số FP32, biểu diễn 6-bit lý tưởng chỉ cần khoảng 18.75 MB, chưa tính overhead của scale, zero-point và cách đóng gói bit trong hệ thống triển khai.

Cần phân biệt giữa tiềm năng nén lý thuyết và kích thước file thực tế. Trong các framework phổ biến, trọng số 6-bit có thể không được đóng gói sát bit ngay lập tức mà được lưu trong kiểu dữ liệu 8-bit hoặc trong cấu trúc tensor có metadata. Khi đó, mức giảm thực tế có thể thấp hơn 5.33 lần. Tuy nhiên, phân tích theo bit-width vẫn cho thấy Q6 có lợi thế rõ ràng về bộ nhớ so với FP32, đặc biệt khi triển khai trên thiết bị biên có băng thông bộ nhớ hạn chế.

Ngoài dung lượng lưu trữ, lượng tử hóa còn có thể giảm chi phí truy cập bộ nhớ và mở đường cho tính toán số nguyên hiệu quả hơn nếu phần cứng hỗ trợ. Đây là lý do Q6 có ý nghĩa thực tiễn: nó không chỉ là kỹ thuật giảm kích thước mô hình, mà còn là bước chuẩn bị cho triển khai nhận dạng khuôn mặt trên các hệ thống tài nguyên thấp.

4.9 Kết luận

Từ các kết quả thực nghiệm và phân tích trên, có thể kết luận rằng phương pháp đề xuất là một hướng tiếp cận hiệu quả cho bài toán tối ưu hóa mô hình nhận dạng khuôn mặt 6-bit. Việc kết hợp teacher full-precision, student Q6, hàm mất mát β -MSE, lịch huấn luyện ba pha và tập dữ liệu thực được tinh lọc giúp giảm đáng kể suy giảm do lượng tử hóa, đặc biệt ở các giao thức xác minh nghiêm ngặt như $\text{TAR@FAR}=10^{-4}$. So với PTQ, student sau fine-tuning phục hồi tốt hơn hình học embedding và duy trì khả năng phân biệt trên nhiều benchmark có biến thiên pose và age.

Một đóng góp quan trọng của phương pháp là chứng minh rằng chất lượng dữ liệu và cách điều phối tối ưu có thể quan trọng không kém quy mô dữ liệu. Thay vì phụ thuộc vào hàng trăm nghìn ảnh tổng hợp, tập dữ liệu thực khoảng 53.5k ảnh vẫn cung cấp đủ tín hiệu để student học các biến thiên có giá trị cao. Khi kết hợp với observer freezing, quá trình tối ưu trở nên ổn định hơn vì dải lượng tử, scale và zero-point không còn dao động kéo dài trong suốt quá trình huấn luyện. Nhờ đó, mô hình có thể hội tụ trong số iteration thấp hơn đáng kể so với các hướng huấn luyện quy mô lớn.

Các phân tích về recovery rate, relative gap, Grad-CAM và chi phí lưu trữ cho thấy lợi ích của Q6 không chỉ nằm ở việc giảm bit-width. Lượng tử hóa 6-bit, nếu được huấn luyện đúng cách, còn có thể đóng vai trò như một ràng buộc regularization giúp student tập trung hơn vào các vùng đặc trưng ổn định của khuôn mặt. Vì vậy, kết quả của khóa luận ủng hộ nhận định rằng nhận dạng khuôn mặt low-bit cần được đánh giá đồng thời trên hiệu năng xác minh, độ bền vững embedding, chi phí hội tụ và khả năng triển khai thực tế.

4.10 Hạn chế và hướng phát triển

Phương pháp vẫn còn một số hạn chế. Thứ nhất, hiệu quả phụ thuộc vào chất lượng teacher full-precision; nếu teacher có embedding chưa ổn định, student sẽ học theo một

mốc tham chiếu chưa tối ưu. Thứ hai, hệ số β cần được lựa chọn theo kiến trúc và dữ liệu, nên có thể cần thêm chiến lược tự động điều chỉnh β theo từng giai đoạn huấn luyện. Thứ ba, lợi ích lưu trữ và tốc độ inference cần được đo trực tiếp trên phần cứng triển khai thực tế để tách bạch giữa fake quantization trong huấn luyện và quantization thực trong inference.

Các hướng phát triển tiếp theo gồm mở rộng phương pháp xuống 4-bit, đánh giá trên phần cứng Edge AI, thử nghiệm thêm các kiến trúc nhẹ và nghiên cứu chiến lược chọn dữ liệu chủ động. Đặc biệt, việc tự động phát hiện các mẫu pose, age hoặc illumination khó có thể giúp tập dữ liệu tinh lọc trở nên hiệu quả hơn mà không cần tăng mạnh số lượng ảnh.

Phụ lục A

Thí nghiệm bổ sung với iResNet-18 trên CIFAR-10

Bên cạnh các thí nghiệm nhận dạng khuôn mặt, khóa luận thực hiện thêm một thí nghiệm phụ với iResNet-18 trên CIFAR-10 nhằm quan sát rõ hơn vai trò của QAT và KD trong bối cảnh phân loại ảnh có kiểm soát. Mục tiêu của thí nghiệm này không phải thay thế các benchmark nhận dạng khuôn mặt, mà dùng như một kiểm chứng bổ sung về hành vi của lượng tử hóa ở các mức bit khác nhau.

Bảng A.1 tổng hợp kết quả accuracy của iResNet-18 trong nhiều kịch bản: teacher FP32, QAT trực tiếp, QAT kết hợp KD bằng dữ liệu tổng hợp GAN, huấn luyện từ đầu trên dữ liệu gốc CIFAR-10, huấn luyện từ đầu kết hợp KD, và KD trực tiếp từ khởi tạo ngẫu nhiên với dữ liệu GAN.

Kết quả cho thấy QAT trực tiếp từ mô hình FP32 nhưng không có KD gần như thất bại, với accuracy chỉ quanh 8–11%. Điều này cho thấy việc đưa mô hình vào cơ chế lượng tử hóa mà thiếu tín hiệu hướng dẫn phù hợp có thể làm quá trình tối ưu mất ổn định nghiêm trọng. Khi bổ sung KD với dữ liệu tổng hợp GAN, hiệu năng được phục hồi mạnh: Q6 + KD đạt 82.56%, gần với teacher FP32 83.40%.

Khi huấn luyện từ đầu trên dữ liệu gốc CIFAR-10, các cấu hình Q16, Q8 và Q6 đều đạt quanh 82–83%, cho thấy mô hình lượng tử có thể học tốt nếu được tối ưu từ đầu trong điều kiện dữ liệu đầy đủ. Đặc biệt, khi kết hợp KD, Q6 đạt 84.09%, vượt teacher FP32 trong bảng này. Điều này củng cố nhận định rằng KD không chỉ giúp phục hồi sai số lượng tử hóa, mà còn có thể đóng vai trò regularization giúp student học biểu diễn ổn định hơn.

Kịch bản KD trực tiếp với dữ liệu GAN từ khởi tạo ngẫu nhiên cũng đạt kết quả khá cao, ví dụ Q6 đạt 82.46%. Điều này cho thấy tín hiệu teacher có thể truyền thông tin hữu ích ngay cả khi không dùng trực tiếp dữ liệu gốc, miễn là dữ liệu tổng hợp cung cấp phân bố đủ gần để student học được ranh giới quyết định. Tuy nhiên, kết quả Q4 thấp hơn các mức bit còn lại, cho thấy khi số bit quá thấp, năng lực biểu diễn của student bị

Bảng A.1: Kết quả accuracy (%) của iResNet-18 trên CIFAR-10 trong các kịch bản huấn luyện khác nhau.

Thiết lập	Lần 1	Lần 2	Lần 3	Acc
Mô hình FP32 (Teacher)				
FP32 (Teacher)	83.40	82.46	83.52	83.40
Lượng tử hóa trực tiếp bằng QAT				
QAT Q16	8.27	9.99	9.71	8.27
QAT Q8	10.59	13.59	10.25	10.59
QAT Q6	10.75	10.98	7.86	10.75
QAT Q4	10.61	8.87	10.62	10.61
QAT kết hợp KD với dữ liệu tổng hợp GAN				
QAT Q16 + KD	83.28	83.45	83.10	83.28
QAT Q8 + KD	82.53	83.52	82.22	82.76
QAT Q6 + KD	82.48	82.61	82.60	82.56
QAT Q4 + KD	81.64	82.03	80.89	81.52
Huấn luyện từ đầu trên CIFAR-10				
OriData Q16	81.77	83.36	83.65	82.93
OriData Q8	83.48	84.21	81.96	83.22
OriData Q6	83.15	83.05	82.69	82.96
OriData Q4	82.44	81.84	81.73	82.00
Huấn luyện từ đầu kết hợp KD				
OriData Q16 + KD	84.34	84.50	84.65	84.34
OriData Q8 + KD	84.06	84.48	84.86	84.06
OriData Q6 + KD	84.09	83.77	84.57	84.09
OriData Q4 + KD	82.09	83.34	83.21	82.09
KD trực tiếp với dữ liệu GAN từ khởi tạo ngẫu nhiên				
randParams Q16 + KD	83.54	82.88	83.32	83.25
randParams Q8 + KD	82.88	82.61	83.21	82.90
randParams Q6 + KD	82.88	81.79	82.72	82.46
randParams Q4 + KD	81.19	81.48	81.93	81.53


giới hạn rõ hơn.

Tóm lại, thí nghiệm CIFAR-10 bổ sung cho các kết quả nhận dạng khuôn mặt bằng cách cho thấy vai trò nhất quán của KD trong môi trường lượng tử hóa. Ở cả bài toán phân loại và nhận dạng khuôn mặt, việc chỉ lượng tử hóa mô hình là chưa đủ; student cần tín hiệu hướng dẫn từ teacher hoặc chiến lược huấn luyện phù hợp để phục hồi hiệu năng sau khi giảm bit.

A.1 Phân tích nhầm lẫn lớp Bird và Dog dưới lượng tử hóa

Để hiểu rõ hơn ảnh hưởng của lượng tử hóa trên CIFAR-10, phụ lục bổ sung phân tích confusion matrix cho hai mức bit Q8 và Q6, như minh họa trong Hình A.1. Trọng tâm là hai lớp Bird và Dog vì hai lớp này thể hiện hành vi khác nhau khi giảm bit-width. Với lớp Bird, số mẫu bị nhầm thành Airplane tăng mạnh từ 37 ở Q8 lên 94 ở Q6. Đồng

thời, số mẫu Bird được phân loại đúng giảm từ 845 xuống 630. Điều này cho thấy Bird là lớp nhạy cảm với lượng tử hóa hơn, đặc biệt khi các chi tiết hình dạng nhỏ như cánh, đuôi, đường viền thân hoặc texture lông bị làm mờ bởi sai số làm tròn ở 6-bit.



(a) Confusion matrix của mô hình Q8.

(b) Confusion matrix của mô hình Q6.

Hình A.1: So sánh confusion matrix giữa Q8 và Q6 trên CIFAR-10.


Nguyên nhân chính là Bird trong CIFAR-10 có độ biến thiên nội lớp lớn: có mẫu chim bay trên nền trời, chim đứng trên cành, chim nhỏ chiếm ít diện tích ảnh và chim bị che khuất bởi nền phức tạp. Ở độ phân giải thấp của CIFAR-10, các đặc trưng phân biệt Bird với Airplane nhiều khi nằm ở các chi tiết nhỏ và biên mảnh. Khi lượng tử hóa xuống Q6, chỉ còn 64 mức biểu diễn cho activation hoặc trọng số, nên các tín hiệu cường độ thấp dễ bị triệt tiêu hoặc gộp vào cùng mức lượng tử. Vì vậy, embedding của một số mẫu Bird có thể dịch gần hơn về vùng đặc trưng của Airplane, đặc biệt với các ảnh chim đang bay có silhouette tương tự máy bay.

Ngược lại, lớp Dog tuy vẫn có nhầm lẫn với Cat, nhưng không suy giảm theo cùng cách. Số mẫu Dog bị nhầm thành Cat gần như không tăng nhiều, từ 119 ở Q8 lên 123 ở Q6, trong khi số mẫu Dog được phân loại đúng tăng từ 687 lên 790. Điều này cho thấy Q6 không nhất thiết làm mọi lớp tệ hơn; với các lớp có đặc trưng hình khối lớn hơn như Dog, lượng tử hóa có thể đóng vai trò như regularization, làm giảm phụ thuộc vào nhiều texture nhỏ và giữ lại các tín hiệu hình dạng tổng quát như đầu, thân, tai hoặc tư thế. Do đó, Dog có thể ổn định hơn Bird trong điều kiện giảm bit-width.

A.2 Trực quan hóa không gian đặc trưng bằng t-SNE

Bên cạnh confusion matrix, Hình A.2 trực quan hóa không gian đặc trưng của mô hình FP32 và Q6 bằng t-SNE. Ở FP32, nhiều cụm lớp vẫn có ranh giới tương đối rõ, nhưng các lớp có hình dạng hoặc bối cảnh gần nhau vẫn xuất hiện vùng giao thoa. Khi chuyển sang Q6, cấu trúc cụm tổng thể vẫn được giữ lại, cho thấy student lượng tử hóa vẫn bảo toàn phần lớn hình học biểu diễn. Tuy nhiên, một số vùng chồng lấn trở nên rõ

hơn, đặc biệt ở các lớp có đặc trưng thị giác phụ thuộc nhiều vào chi tiết nhỏ.



(a) t-SNE của mô hình FP32.

(b) t-SNE của mô hình Q6.

Hình A.2: So sánh t-SNE giữa FP32 và Q6 trên CIFAR-10.

Kết quả t-SNE củng cố nhận định từ confusion matrix: lượng tử hóa 6-bit không chỉ làm giảm độ chính xác theo nghĩa tổng quát, mà còn làm thay đổi khoảng cách tương đối giữa các cụm đặc trưng. Với Bird, các mẫu dễ nhầm thường nằm gần vùng Airplane hơn vì cả hai có thể chia sẻ nền trời, hướng bay và đường biên mảnh. Khi các chi tiết nhỏ bị mất, mô hình khó tách Bird khỏi Airplane. Với Dog, cụm đặc trưng có thể chịu tác động khác: các tín hiệu hình dạng lớn vẫn đủ mạnh nên Q6 không làm lớp này suy giảm tương ứng, thậm chí có thể giảm overfitting vào texture nhiễu. Do đó, phân tích kết hợp confusion matrix và t-SNE cho thấy độ nhạy với lượng tử hóa phụ thuộc mạnh vào bản chất thị giác của từng lớp, chứ không chỉ phụ thuộc vào bit-width trung bình của toàn mô hình.

Tài liệu tham khảo

- [1] Yoshua Bengio, Patrice Simard, and Paolo Frasconi. Learning long-term dependencies with gradient descent is difficult. *IEEE Transactions on Neural Networks*, 5(2):157–166, 1994.
- [2] Fadi Boutros, Naser Damer, and Arjan Kuijper. Quantface: Towards lightweight face recognition by synthetic data low-bit quantization. In *Proceedings of the 26th International Conference on Pattern Recognition (ICPR)*, pages 855–862. IEEE, August 2022.
- [3] E. Caldeira, P. C. Neto, M. Huber, N. Damer, and A. F. Sequeira. Model compression techniques in biometrics applications: A survey. *Information Fusion*, 114:102657, 2025.
- [4] Qiong Cao, Li Shen, Weidi Xie, Omkar M. Parkhi, and Andrew Zisserman. Vggface2: A dataset for recognising faces across pose and age. In *Proceedings of the IEEE International Conference on Automatic Face and Gesture Recognition (FG)*, pages 67–74, 2018.
- [5] Jiankang Deng, Jia Guo, Niannan Xue, and Stefanos Zafeiriou. Arcface: Additive angular margin loss for deep face recognition. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 4690–4699, 2019.
- [6] Xavier Glorot and Yoshua Bengio. Understanding the difficulty of training deep feed-forward neural networks. In *Proceedings of the Thirteenth International Conference on Artificial Intelligence and Statistics*, pages 249–256, 2010.
- [7] Jianping Gou, Baosheng Yu, Stephen J. Maybank, and Dacheng Tao. Knowledge distillation: A survey. *International Journal of Computer Vision*, 129(6):1789–1819, 2021.
- [8] Chuan Guo, Geoff Pleiss, Yu Sun, and Kilian Q. Weinberger. On calibration of modern neural networks. In *Proceedings of the International Conference on Machine Learning (ICML)*, pages 1321–1330, 2017.

- [9] Song Han, Huizi Mao, and William J. Dally. Deep compression: Compressing deep neural networks with pruning, trained quantization and huffman coding. In *Proceedings of the International Conference on Learning Representations (ICLR)*, 2016.
- [10] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 770–778, 2016.
- [11] Ramya Hebbalaguppe, Mayank Baranwal, Kumar Anand, and Chetan Arora. Calibration transfer via knowledge distillation. In *Proceedings of the Asian Conference on Computer Vision (ACCV)*, pages 513–530, 2024.
- [12] Geoffrey Hinton, Oriol Vinyals, and Jeff Dean. Distilling the knowledge in a neural network. *arXiv preprint arXiv:1503.02531*, 2015.
- [13] Andrew G. Howard et al. Mobilenets: Efficient convolutional neural networks for mobile vision applications. *arXiv preprint arXiv:1704.04861*, 2017.
- [14] Gary B. Huang, Manu Ramesh, Tamara Berg, and Erik Learned-Miller. Labeled faces in the wild: A database for studying face recognition in unconstrained environments. Technical Report 07-49, University of Massachusetts, Amherst, October 2007.
- [15] Itay Hubara, Matthieu Courbariaux, Daniel Soudry, Ran El-Yaniv, and Yoshua Bengio. Quantized neural networks: Training neural networks with low precision weights and activations. *Journal of Machine Learning Research*, 18(187):1–30, 2017.
- [16] Sergey Ioffe and Christian Szegedy. Batch normalization: Accelerating deep network training by reducing internal covariate shift. In *International Conference on Machine Learning*, pages 448–456, 2015.
- [17] Benoit Jacob et al. Quantization and training of neural networks for efficient integer-arithmetic-only inference. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018.
- [18] Raghuraman Krishnamoorthi. Quantizing deep convolutional networks for efficient inference: A whitepaper. *arXiv preprint arXiv:1806.08342*, 2018.
- [19] Weiyang Liu, Yandong Wen, Zhiding Yu, Ming Li, Bhiksha Raj, and Le Song. Sphreface: Deep hypersphere embedding for face recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 212–220, 2017.
- [20] Yan Luo, Yangcheng Gao, Zhao Zhang, Haijun Zhang, Mingliang Xu, and Meng Wang. Long-range zero-shot generative deep network quantization. *arXiv preprint arXiv:2211.06816*, 2022.

- [21] Daisuke Miyashita, Edward H. Lee, and Boris Murmann. Convolutional neural networks using logarithmic data representation. *arXiv preprint arXiv:1603.01025*, 2016.
- [22] Stylianos Moschoglou, Athanasios Papaioannou, Christos Sagonas, Jiankang Deng, Irene Kotsia, and Stefanos Zafeiriou. Agedb: The first manually collected, in-the-wild age database. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*, pages 1997–2005, Honolulu, HI, USA, July 2017.
- [23] Mahdi Pakdaman Naeini, Gregory F. Cooper, and Milos Hauskrecht. Obtaining well calibrated probabilities using bayesian binning. In *Proceedings of the AAAI Conference on Artificial Intelligence*, pages 2901–2907, 2015.
- [24] Markus Nagel, Mart van Baalen, Tijmen Blankevoort, and Max Welling. Data-free quantization through weight equalization and bias correction. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 1325–1334, 2019.
- [25] Jeremy Nixon, Michael W. Dusenberry, Linchuan Zhang, Ghassen Jerfel, and Dustin Tran. Measuring calibration in deep learning. In *CVPR Workshops*, 2019.
- [26] Adriana Romero, Nicolas Ballas, Samira Ebrahimi Kahou, Antoine Chassang, Carlo Gatta, and Yoshua Bengio. Fitnets: Hints for thin deep nets. In *Proceedings of the International Conference on Learning Representations (ICLR)*, 2015.
- [27] Rasmus Rothe, Radu Timofte, and Luc Van Gool. Dex: Deep expectation of apparent age from a single image. In *Proceedings of the IEEE International Conference on Computer Vision Workshops (ICCVW)*, pages 10–15, 2015.
- [28] Florian Schroff, Dmitry Kalenichenko, and James Philbin. Facenet: A unified embedding for face recognition and clustering. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 815–823, 2015.
- [29] Ramprasaath R. Selvaraju, Michael Cogswell, Abhishek Das, Ramakrishna Vedantam, Devi Parikh, and Dhruv Batra. Grad-cam: Visual explanations from deep networks via gradient-based localization. In *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, pages 618–626, 2017.
- [30] Soumyadip Sengupta, Jun-Cheng Chen, Carlos D. Castillo, Vishal M. Patel, Rama Chellappa, and David W. Jacobs. Frontal to profile face verification in the wild. In *Proceedings of the IEEE Winter Conference on Applications of Computer Vision (WACV)*, pages 1–9, Lake Placid, NY, USA, March 2016.

- [31] Yaniv Taigman, Ming Yang, Marc'Aurelio Ranzato, and Lior Wolf. Deepface: Closing the gap to human-level performance in face verification. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 1701–1708, 2014.
- [32] C.-P. Tran, A.-K. N. Vu, and V.-T. Nguyen. Baby learning with vision transformer for face recognition. In *Proceedings of the International Conference on Multimedia Analysis and Pattern Recognition (MAPR)*, 2022.
- [33] Hao Wang, Yitong Wang, Zheng Zhou, Xing Ji, Dihong Gong, Jingchao Zhou, Zhifeng Li, and Wei Liu. Cosface: Large margin cosine loss for deep face recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018.
- [34] Longguang Wang, Xiaoyu Dong, Yingqian Wang, Li Liu, Wei An, and Yulan Guo. Learnable lookup table for neural network quantization. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 12423–12433, 2022.
- [35] Dong Yi, Zhen Lei, Shengcai Liao, and Stan Z. Li. Learning face representation from scratch. *arXiv preprint arXiv:1411.7923*, 2014.
- [36] Xiangyu Zhang, Xinyu Zhou, Mengxiao Lin, and Jian Sun. Shufflenet: An extremely efficient convolutional neural network for mobile devices. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018.
- [37] Shuchang Zhao, Huihui Ding, Yuchen Zhang, Zhen Han, Yunchao Guo, Kaiqiang Xu, Zhiqiang Lin, Yifan Wang, and Jian Tang. Lq-nets: Learned quantization for highly accurate and compact deep neural networks. In *Proceedings of the European Conference on Computer Vision (ECCV)*, pages 365–382, 2018.
- [38] Tianyue Zheng and Weihong Deng. Cross-pose lfw: A database for studying cross-pose face recognition in unconstrained environments. Technical Report 18-01, Beijing University of Posts and Telecommunications, February 2018.
- [39] Tianyue Zheng, Weihong Deng, and Jiani Hu. Cross-age lfw: A database for studying cross-age face recognition in unconstrained environments. *CoRR*, abs/1708.08197, 2017.
- [40] Aojun Zhou, Anbang Yao, Yiwen Guo, Lin Xu, and Yurong Chen. Incremental network quantization: Towards lossless cnns with low-precision weights. In *International Conference on Learning Representations (ICLR)*, 2017.

- [41] Shuchang Zhou, Yuxin Wu, Zekun Ni, Xinyu Zhou, He Wen, and Yuheng Zou. Dorefa-net: Training low bitwidth convolutional neural networks with low bitwidth gradients. *arXiv preprint arXiv:1606.06160*, 2016.